



Université Sultan Moulay Slimane
École Nationale des Sciences Appliquées
Khouribga



Mémoire de Projet de Fin d'Études

En vue de l'obtention du diplôme de

MASTER

Filière : **Informatique et Mathématiques pour la Science des Données**

Super-résolution de visages masqués

Architecture MEFSR-GAN : suppression de masque, guidage par contours
et réseau antagoniste

Réalisé par :

Sara Maggag

Encadrante :

Pr. Lamghari Nidal

Soutenu le 23 Juin 2026 devant le jury :

Pr. Soussi	Président(e)
Pr. Tabaa	Examineur(trice)
Pr. Lamghari	Encadrante

Année universitaire : 2025 – 2026

Dédicace

*À mes parents,
leur amour inconditionnel, leurs sacrifices silencieux
et leur confiance ont été les piliers de ce parcours.*

*À mes frères,
pour leur présence réconfortante, leurs rires partagés
et leurs encouragements de chaque instant.*

*À Rachida et Dounia
pour une amitié sincère, des discussions sans fin
et un soutien sans faille tout au long de ce chemin.*

*À ma famille et à mes proches,
pour leur affection discrète mais toujours présente,
leur fierté et leurs prières.*

*Je dédie ce travail à toutes les mains tendues,
aux cœurs qui m'ont porté,
et à ceux qui croient encore que les efforts paient.*

Remerciements

Je tiens à adresser mes plus sincères remerciements à mon encadrante, Professeur Lamghari Nidal, et à mon Co-encadrant Yazid Safiny. Leur accompagnement rigoureux, leurs conseils avisés et leur soutien indéfectible m'ont été précieux tout au long de ce projet de fin d'études. La disponibilité du Professeur Lamghari, son expertise scientifique et ses encouragements constants m'ont permis de mener à bien ce travail dans les meilleures conditions possibles.

Un grand merci également aux membres du jury pour l'intérêt qu'ils porteront à ce travail et le temps qu'ils y consacreront.

Mes remerciements vont à l'ensemble du corps professoral de l'ENSA Khouribga pour la qualité de la formation dispensée, qui m'a permis d'acquérir les compétences essentielles à la réalisation de ce projet.

Enfin, un immense merci à ma famille et à mes proches pour leur soutien inconditionnel et leurs encouragements permanents, qui m'ont aidé à surmonter les défis de cette année.

Résumé

La super-résolution faciale (Face Super-Resolution, FSR) vise à reconstruire des images faciales haute résolution à partir d'images basse résolution. Avec l'avènement de la pandémie de COVID-19, le port généralisé de masques faciaux a introduit une nouvelle problématique : des occlusions importantes rendant les méthodes classiques moins efficaces.

Nous proposons MEFSR-GAN (Masked Edge-guided Face Super-Resolution Generative Adversarial Network), une architecture modulaire combinant trois composants : un module de suppression de masque inspiré de JDSR-GAN, un module de fusion guidée par contours avec mécanisme d'attention, et un module de super-résolution basé sur ESRGAN utilisant des blocs RRDB. L'architecture traite simultanément deux tâches interdépendantes : la suppression du masque et la super-résolution $4\times$ ($32\times 32 \rightarrow 128\times 128$). Les contours extraits via l'algorithme de Canny, combinés à un mécanisme d'attention spatiale et canal, permettent une fusion adaptative des caractéristiques.

Le modèle est entraîné sur CelebA-HQ masqué (24 678 paires) avec une fonction de perte composite : perte pixel (MSE, MAE), perte perceptuelle (VGG16), perte d'identité (FaceNet) et perte structurelle (SSIM). La version finale retenue (v3.1, entraînement adversarial conjoint) atteint un PSNR de 24,49 dB et un SSIM de 0,7902 sur l'ensemble de test, surpassant la baseline bicubique (23,00 dB) tout en maintenant un modèle compact de 9,4 millions de paramètres, soit $3,9\times$ plus léger que JDSR-GAN.

Mots-clés : Super-résolution faciale, suppression de masque, GAN, ESRGAN, RRDB, attention spatiale et channel, contours de Canny, apprentissage profond, CelebA-HQ.

Abstract

Face super-resolution (FSR) aims to reconstruct high-resolution facial images from low-resolution inputs. With the COVID-19 pandemic, the widespread use of facial masks introduced a significant challenge : heavy occlusions that render classical super-resolution methods less effective.

We propose MEFSR-GAN (Masked Edge-guided Face Super-Resolution Generative Adversarial Network), a modular architecture combining three main components : a mask removal module inspired by JDSR-GAN, an edge-guided fusion module with attention mechanism, and a super-resolution module based on ESRGAN using RRDB blocks. The architecture simultaneously addresses two interdependent tasks : facial mask removal and $4\times$ super-resolution ($32\times 32 \rightarrow 128\times 128$). Edges extracted via the Canny algorithm, combined with channel and spatial attention mechanisms, enable adaptive feature fusion.

The model is trained on the masked CelebA-HQ dataset (24,678 image pairs) using a composite loss integrating pixel loss (MSE, MAE), perceptual loss (VGG16), identity loss (FaceNet), and structural loss (SSIM). The final retained version (v3.1, joint adversarial training) achieves a PSNR of 24.49 dB and an SSIM of 0.7902 on the test set, outperforming the bicubic baseline (23.00 dB) while remaining a compact model of 9.4 million parameters — $3.9\times$ lighter than JDSR-GAN.

Keywords : Face super-resolution, mask removal, GAN, ESRGAN, RRDB, channel and spatial attention, Canny edges, deep learning, CelebA-HQ.

الملخص

يهدف مجال تحسين الدقة الفائقة للوجوه إلى إعادة بناء صور وجه عالية الدقة انطلاقاً من صور منخفضة الدقة. ومع انتشار جائحة كوفيد-19، أصبح ارتداء الأقنعة الواقية شائعاً، مما أفرز تحدياً جديداً يتمثل في احتجاب أجزاء من الوجه وجعل أساليب تحسين الدقة التقليدية أقل فعالية.

نقترح نموذج *MEFSR-GAN*، وهو نموذج معياري يجمع بين ثلاثة مكونات رئيسية: وحدة لإزالة القنوات مستوحاة من *JDSR-GAN*، ووحدة دمج موجهة بالحواف مدعومة بآلية انتباه، ووحدة لتحسين الدقة مبنية على *ESRGAN* باستخدام كتل *RRDB*. تعالج المعمارية المقترحة مهمتين مترابطتين في آن واحد: إزالة القنوات وتحسين الدقة بمعدل $4 \times (128 \times 128 \rightarrow 32 \times 32)$. وتُستغل الحواف المستخرجة بخوارزمية *Canny* مع آليات انتباه مكانية وقنوية لتحقيق دمج تكيفي للخصائص.

تم تدريب النموذج على مجموعة بيانات *CelebA-HQ* المقنّعة (24,678 زوجاً) باستخدام دالة فقد مركبة تشمل: فقد البكسل (MAE MSE)، فقد الإدراكي (*VGG16*)، فقد الهوية (*FaceNet*)، والفقْد البنيوي (*SSIM*). أظهرت نتائج النسخة النهائية المعتمدة، *v3.1* (التدريب التنافسي المشترك) فعالية النهج المقترح، إذ حقق قيمة *PSNR* بلغت 24.49 ديسيبل و *SSIM* قدرها (0.7902) على مجموعة الاختبار، متفوقاً على النسخة الأساسية (23.00).

الكلمات المفتاحية: تحسين دقة الوجه، إزالة القنوات، الشبكات التوليدية التنافسية، *RRDB*، *ESRGAN*، الانتباه المكاني والقنوي، حواف *Canny*، التعلم العميق، *CelebA-HQ*.

Table des matières

Dédicace	i
Remerciements	ii
Résumé	iii
Abstract	iv
v	الملخص
Liste des figures	ix
Liste des tableaux	xi
Liste des abréviations	xii
Introduction générale	1
1 Contexte général et étude du domaine	3
1.1 Présentation du sujet	3
1.1.1 Vision par ordinateur	3
1.1.2 Apprentissage profond	4
1.2 Définitions et concepts fondamentaux	5
1.2.1 Définition de la super-résolution	5
1.2.2 Caractère mal posé du problème	5
1.2.3 Approches classiques vs apprentissage profond	6
1.2.4 Super-résolution par apprentissage profond	6
1.2.5 Réseaux antagonistes génératifs (GAN)	7
1.3 Problématique	8
1.3.1 Défis de la super-résolution faciale	8
1.3.2 Impact des masques faciaux	8
1.3.3 Formulation du problème	8
1.3.4 Problème traité	9
1.4 Solution proposée	9
1.4.1 Approche progressive	10

1.5	Objectifs du travail	10
1.5.1	Objectifs fonctionnels	10
1.5.2	Objectifs quantitatifs	10
1.5.3	Objectifs méthodologiques	11
1.6	Applications existantes	11
2	État de l'art	12
2.1	Revue des travaux existants	12
2.1.1	JDSR-GAN (Joint Denoising and Super-Resolution GAN)	12
2.1.2	EFBPGAN (Edge Fusion Back Projection GAN)	16
2.1.3	EIPNet (Edge and Identity Preserving Network)	19
2.1.4	FCSR-GAN (Joint Face Completion and Super-Resolution GAN)	22
2.1.5	FSRNet (Face Super-Resolution Network)	25
2.1.6	SANet (Self-similarity Attention Network)	28
2.1.7	SLNet (Self-attention Learning Network)	31
2.2	Positionnement et inspirations de notre travail	35
2.3	Limites des approches existantes	35
3	Méthodologie proposée	37
3.1	Architectures implémentées	37
3.1.1	Description des trois modules fondamentaux	38
3.1.2	Version 1.0.1 : ResNet simple (MSE + Perceptuelle + Identité)	39
3.1.3	Version 1.0.2 : Ajout de la perte SSIM	40
3.1.4	Version 1.0.3 : MAE, data augmentation et régularisation	40
3.1.5	Version 2.0 (12 RRDB) : Attention et ESRGAN complet	40
3.1.6	Version 2.0 Light (4 RRDB) : Adaptation à la basse résolution	40
3.1.7	Version 2.0 Light New (4 RRDB + MAE×0,8 + MSE×0,2) : Optimisation de la perte pixel	41
3.1.8	Version 3.0 : Entraînement adversarial — MEFSR-GAN	41
3.1.9	Version 3.1 : Entraînement adversarial conjoint (end-to-end)	43
3.1.10	Version 4 : Discriminateur WGAN-GP	45
3.2	Fonctions de perte détaillées	47
3.2.1	Perte pixel (MAE + MSE)	47
3.2.2	Perte perceptuelle (VGG16)	48
3.2.3	Perte d'identité (FaceNet)	48
3.2.4	Perte SSIM	48
3.2.5	Perte adversariale (versions GAN)	49
3.2.6	Récapitulatif des coefficients	49
4	Résultats Expérimentaux	51
4.1	Données expérimentales	51

4.1.1	Description du dataset	51
4.1.2	Prétraitement des données	52
4.1.3	Augmentation des données	53
4.2	Métriques d'évaluation	54
4.2.1	PSNR (Peak Signal-to-Noise Ratio)	54
4.2.2	SSIM (Structural Similarity Index Measure)	54
4.3	Protocole expérimental	55
4.3.1	Environnement expérimental	55
4.3.2	Hyperparamètres d'entraînement	55
4.3.3	Résultats quantitatifs	56
4.3.4	Résultats qualitatifs sur l'ensemble de validation	58
4.3.5	Évaluation de la robustesse sur l'ensemble de test	61
4.3.6	Analyse synthétique des performances par version	63
4.3.7	Version 3.1 (GAN end-to-end) : Résultats finaux	63
4.4	Comparaison avec l'état de l'art	67
Conclusion générale et perspectives		69
Bibliographie		71

Table des figures

1.1	Architecture générale proposée de MEFSR-GAN	9
2.1	Architecture du réseau proposé JDSR-GAN. Source : extrait de [5].	13
2.2	Architecture du premier module, dédié au débruitage. Source : extrait de [5].	14
2.3	Architecture du second module, dédié à la super-résolution faciale. Source : extrait de [5].	15
2.4	Architecture de la méthode EFBPGAN. Source : extrait de [1].	18
2.5	Architecture de la méthode EIPNet. Source : extrait de [2].	21
2.6	Architecture de la méthode FCSR-GAN. Source : extrait de [3].	24
2.7	Architecture de la méthode FSRNet. Source : extrait de [4].	27
2.8	Architecture de la méthode SANet. Source : extrait de [6].	30
2.9	Architecture de la méthode SLNet. Source : extrait de [7].	32
3.1	Architecture progressive globale du modèle MEFSR-GAN : évolution de la version 1 (ResNet simple) à la version 3 (avec discriminateur GAN).	38
4.1	Exemple de paire d'images du dataset. À gauche : image d'entrée basse résolution (32×32) avec masque. À droite : image cible haute résolution (128×128) sans masque.	52
4.2	À gauche : courbes d'entraînement de la version v1.0.2 (MSE + Percep- tual + Identity + SSIM). À droite : courbes d'entraînement de la version v1.0.3 Light. Les deux versions montrent une convergence stable avec une diminution progressive de la loss et une amélioration du PSNR.	57
4.3	À gauche : courbes d'entraînement de la version v2.0 Light. À droite : courbes d'entraînement de la version v2.0 Light après 200 epochs. Les deux expériences montrent une convergence stable avec une diminution progressive de la loss totale et une amélioration du PSNR de validation au cours de l'apprentissage.	57
4.4	Courbes d'entraînement de la version v3.0 : Phase 1 (époches 1–50) – pré-entraînement du générateur seul ; Phase 2 (époches 51–75) – introduc- tion du discriminateur PatchGAN et entraînement adversarial. La chute de la Loss D à l'époque 65 correspond à la correction des hyperparamètres appliquée pour remédier au phénomène d'identity drift (voir la description de la correction dans le chapitre 3).	58

4.5	Courbes d'entraînement de la version v3.1 (entraînement conjoint). La courbe bleue (Train Loss G) montre la décroissance régulière de la perte du générateur, passant de 0,8247 à l'époque 1 à 0,4825 à l'époque 80. La courbe orange (Validation Loss) descend de 0,6500 à l'époque 5 à son minimum de 0,5204 à l'époque 75, démontrant une excellente capacité de généralisation. Le gap stable (moyenne 0,038) confirme l'absence d'overfitting, et les légères oscillations après l'époque 60 sont caractéristiques de l'équilibrage continu entre générateur et discriminateur dans un GAN. . . .	58
4.6	Résultats qualitatifs de la version 1.	59
4.7	Résultats qualitatifs de la version 2.	59
4.8	Résultats qualitatifs de la version v3.0 GAN (entraînement en deux phases, LSGAN).	60
4.9	Résultats qualitatifs de la version v3.1 GAN (entraînement conjoint, LSGAN).	60
4.10	Résultats qualitatifs de la version v4 (WGAN-GP).	61
4.11	Comparaison côte à côte des reconstructions obtenues par les trois versions GAN sur 7 images du test set. De gauche à droite : entrée LR (masquée), sortie de v3.0 (2 phases), sortie de v3.1 (entraînement conjoint), sortie de v4 (WGAN-GP) et cible HR.	62
4.12	Comparaison visuelle des reconstructions par catégorie de qualité — Version v3.1_GAN. Pour chaque catégorie, le panneau de gauche montre l'entrée basse résolution masquée (Input LR), le panneau du milieu la sortie du modèle (Output SR) avec PSNR et SSIM, et le panneau de droite l'image de référence haute résolution sans masque (Target HR). Les masques sont visualisés en bleu. La qualité visuelle s'améliore clairement des catégories Mauvaise (bas) à Excellente (haut).	65

Liste des tableaux

2.1	Comparaison synthétique des principales méthodes de super-résolution faciale	34
2.2	Sources d’inspiration ayant guidé la conception de MEFSR-GAN	35
3.1	Architecture du discriminateur PatchGAN (v3.0)	42
3.2	Progression du PSNR (validation) et de la Loss_D au fil des époques — v3.1_GAN	45
3.3	Comparaison finale v3.1_GAN et v4 WGAN-GP sur le test set	47
3.4	Coefficients des fonctions de perte par version	49
4.1	Répartition du dataset MEFSR-GAN	53
4.2	Ressources expérimentales et temps d’entraînement	55
4.3	Hyperparamètres d’entraînement pour les versions principales	55
4.4	Comparaison expérimentale des différentes versions de MEFSR-GAN . . .	56
4.5	Distribution de qualité — Version v3.1_GAN (2 469 images test)	64
4.6	Statistiques d’identité — Version v3.1_GAN (2 469 images)	66
4.7	Catégories de préservation d’identité — v3.1_GAN	66
4.8	Comparaison complète avec les méthodes de l’état de l’art	67

Liste des abréviations

BRISQUE	<i>Blind/Referenceless Image Spatial Quality Evaluator</i> – évaluation de qualité d’image sans référence
CBAM	<i>Convolutional Block Attention Module</i> – module d’attention spatiale et canal
CNN	<i>Convolutional Neural Network</i> – Réseau de Neurones Convolutif
DL	<i>Deep Learning</i> – Apprentissage Profond
ESRGAN	<i>Enhanced Super-Resolution Generative Adversarial Network</i>
FID	<i>Fréchet Inception Distance</i> – distance de Fréchet pour évaluer la qualité perceptuelle
FR-PSNR	<i>Facial Region Peak Signal-to-Noise Ratio</i> – PSNR calculé uniquement sur la région faciale
FR-SSIM	<i>Facial Region Structural Similarity Index Measure</i> – SSIM calculé uniquement sur la région faciale
FSR	<i>Face Super-Resolution</i> – Super-Résolution Faciale
GAN	<i>Generative Adversarial Network</i> – Réseau Antagoniste Génératif
HR	<i>High Resolution</i> – Haute Résolution
JDSR-GAN	<i>Joint Denoising and Super-Resolution GAN</i>
JS	<i>Jensen-Shannon divergence</i> – divergence de Jensen-Shannon
LPIPS	<i>Learned Perceptual Image Patch Similarity</i> – similarité perceptuelle apprise
LR	<i>Low Resolution</i> – Basse Résolution
LSGAN	<i>Least Squares Generative Adversarial Network</i>
MAE	<i>Mean Absolute Error</i> – Erreur Absolue Moyenne
MEFSR-GAN	<i>Masked Edge-guided Face Super-Resolution GAN</i>
MS-SSIM	<i>Multi-Scale Structural Similarity Index Measure</i> – SSIM multi-échelle
MSE	<i>Mean Squared Error</i> – Erreur Quadratique Moyenne
MSSIM	<i>Mean Structural Similarity Index Measure</i> – moyenne du SSIM

NRMSE	<i>Normalized Root Mean Square Error</i> – erreur quadratique moyenne normalisée
PSNR	<i>Peak Signal-to-Noise Ratio</i> – Rapport Signal sur Bruit de Crête
ReLU	<i>Rectified Linear Unit</i> – Unité Linéaire Rectifiée
ResNet	<i>Residual Network</i> – Réseau Résiduel
RGB	<i>Red Green Blue</i> – Rouge Vert Bleu
RRDB	<i>Residual in Residual Dense Block</i>
SGD	<i>Stochastic Gradient Descent</i> – Descente de Gradient Stochastique
SISR	<i>Single Image Super-Resolution</i> – Super-Résolution d’Image Unique
SR	<i>Super-Resolution</i> – Super-Résolution
SRCNN	<i>Super-Resolution Convolutional Neural Network</i>
SSIM	<i>Structural Similarity Index Measure</i> – Indice de Similarité Structurelle
TAR	<i>True Acceptance Rate</i> – taux de vraie acceptation (reconnaissance faciale)
VGG	<i>Visual Geometry Group</i>
WGAN-GP	<i>Wasserstein GAN with Gradient Penalty</i>

Introduction générale

La super-résolution faciale (*Face Super-Resolution*, ou FSR) est un domaine important en vision par ordinateur qui cherche à améliorer la résolution et la qualité des images de visages. L'idée est de recréer une image haute résolution (HR) à partir d'une version floue ou dégradée (basse résolution, LR), tout en conservant les détails essentiels : texture de la peau, structure du visage, formes des yeux, du nez, de la bouche... tout doit rester crédible.

Cette technique est souvent utilisée en prétraitement, pour rendre les images plus nettes avant de les exploiter dans des systèmes de reconnaissance faciale [20], d'analyse des expressions ou d'authentification biométrique.

L'arrivée de l'apprentissage profond a véritablement changé la donne. De nombreuses méthodes récentes reposent sur des réseaux de neurones convolutifs (CNN) [15] ou des réseaux antagonistes génératifs (GAN) [13]. Ces architectures profondes apprennent directement les relations complexes entre images basse et haute résolution, ce qui permet d'obtenir des reconstructions de visages plus réalistes et fidèles.

Cependant, depuis la pandémie de COVID-19, un nouveau défi s'est imposé : le port généralisé de masques faciaux, qui occultent entre 30 et 40% du visage. Dans ce contexte, les méthodes classiques de super-résolution deviennent moins efficaces, voire inopérantes. Pourtant, cette problématique précise reste encore peu explorée dans la littérature. Il existe donc un besoin réel d'approches capables de gérer conjointement l'occlusion par masque et la super-résolution.

C'est dans cette perspective que ce projet propose de développer une architecture efficace pour la super-résolution de visages masqués. Nous présentons **MEFSR-GAN** (*Masked Edge-guided Face Super-Resolution Generative Adversarial Network*), un modèle hybride combinant suppression du masque (inspirée de JDSR-GAN [5]), guidage par les contours (inspiré d'EFBPGAN [1]) et super-résolution par blocs RRDB (ESRGAN [9]).

Notre contribution principale est l'architecture MEFSR-GAN, qui combine un module de suppression de masque, un guidage par contours et un réseau antagoniste pour la super-résolution de visages masqués en entrée 32×32 .

Structure du rapport

Ce rapport est organisé en quatre chapitres principaux :

Chapitre 1 : Contexte général et étude du domaine

Ce chapitre présente les fondements théoriques de la vision par ordinateur, de l'apprentissage profond et de la super-résolution d'images. Il introduit les concepts essentiels nécessaires à la compréhension du travail : réseaux de neurones convolutifs, réseaux antagonistes génératifs, métriques d'évaluation et applications de la super-résolution faciale. La problématique et les objectifs y sont également détaillés.

Chapitre 2 : État de l'art

Ce chapitre propose une revue critique et détaillée des méthodes existantes en super-résolution faciale. Il analyse les approches basées sur les priors faciaux (FSRNet [4], SANet [6]), les méthodes traitant les visages masqués (JDSR-GAN [5]), les techniques exploitant les contours (EFBPGAN [1]) ainsi que d'autres travaux, et identifie le gap scientifique que notre travail vise à combler.

Chapitre 3 : Méthodologie proposée

Ce chapitre présente l'architecture MEFSR-GAN et ses différentes versions, justifie les choix de conception et détaille les fonctions de perte utilisées.

Chapitre 4 : Résultats expérimentaux et discussion

Ce chapitre présente le protocole expérimental, les résultats quantitatifs et qualitatifs obtenus, propose une étude d'ablation démontrant l'apport de chaque module, et discute les limites et perspectives du travail.

Enfin, une conclusion générale synthétise les contributions de ce travail et propose des perspectives pour des travaux futurs.

Chapitre 1

Contexte général et étude du domaine

Introduction

La vision par ordinateur est un domaine de l'intelligence artificielle qui vise à permettre aux machines de comprendre et d'interpréter le contenu visuel du monde réel. Parmi les nombreuses tâches de vision par ordinateur, la super-résolution d'images [15] occupe une place centrale en raison de ses applications variées allant de l'imagerie médicale à la surveillance en passant par le divertissement multimédia.

La super-résolution faciale, sous-domaine spécialisé de la super-résolution générique, présente des défis particuliers liés à la nature structurée et sémantique des visages humains. Contrairement aux images naturelles génériques, les visages possèdent une structure géométrique prévisible et des caractéristiques sémantiques spécifiques (yeux, nez, bouche) qui doivent être préservées lors de la reconstruction.

1.1 Présentation du sujet

1.1.1 Vision par ordinateur

La vision par ordinateur étudie les méthodes permettant aux machines d'acquérir, traiter, analyser et comprendre des images ou vidéos. L'objectif est de reproduire certaines capacités du système visuel humain. Ses tâches principales incluent la **classification d'images**, qui consiste à attribuer une catégorie à une image, la **détection d'objets**, qui vise à localiser et identifier des objets dans une scène, et la **segmentation**

sémantique, qui permet d'étiqueter chaque pixel selon sa classe. On y trouve également la **super-résolution** [15], dont l'objectif est de reconstruire une version haute résolution d'une image dégradée, ainsi que la **reconnaissance faciale** [20], qui permet d'identifier ou de vérifier l'identité d'une personne à partir de son visage.

1.1.2 Apprentissage profond

L'apprentissage profond (*Deep Learning*) utilise des réseaux de neurones à plusieurs couches cachées. Contrairement aux approches classiques, il apprend automatiquement des représentations hiérarchiques des données.

Principe des réseaux de neurones

Un réseau de neurones artificiel est composé de neurones organisés en couches : entrée, cachées, sortie. Chaque neurone effectue une combinaison linéaire suivie d'une activation non-linéaire :

$$y = f \left(\sum_i w_i x_i + b \right) \quad (1.1)$$

où x_i sont les entrées, w_i les poids, b le biais, et f une fonction d'activation (ReLU, sigmoïde, tanh).

Réseaux de neurones convolutifs (CNN)

Les CNN exploitent la structure spatiale des images via trois principes : connectivité locale, partage des poids, invariance par translation. Une couche de convolution applique des filtres :

$$Y[i, j] = \sum_m \sum_n X[i + m, j + n] \cdot K[m, n] + b \quad (1.2)$$

où X est l'entrée, K le noyau, Y la carte de caractéristiques.

Entraînement par rétropropagation

Les poids sont appris par minimisation d'une fonction de perte $\mathcal{L}$ via rétropropagation et descente de gradient stochastique (SGD) ou ses variantes (Adam, RMSprop) :

$$w_{t+1} = w_t - \eta \nabla_w \mathcal{L}(w_t) \quad (1.3)$$

avec η le taux d'apprentissage.

1.2 Définitions et concepts fondamentaux

1.2.1 Définition de la super-résolution

La super-résolution d'images est le processus consistant à reconstruire une image haute résolution (HR) I_{HR} à partir d'une image basse résolution (LR) I_{LR} . Mathématiquement, ce problème peut être modélisé comme un problème inverse :

$$I_{LR} = \mathcal{D}(I_{HR}) + n \quad (1.4)$$

où $\mathcal{D}$ est un opérateur de dégradation (sous-échantillonnage, flou, compression) et n représente le bruit additif.

L'objectif de la super-résolution est d'estimer $\hat{I}_{HR}$ à partir de I_{LR} tel que $\hat{I}_{HR}$ soit aussi proche que possible de I_{HR} selon une métrique donnée.

1.2.2 Caractère mal posé du problème

Ce problème est **mal posé** (*ill-posed*) pour trois raisons fondamentales. D'abord, la **non-unicité** : plusieurs images HR peuvent correspondre à la même image LR, rendant la solution indéterminée. Ensuite, l'**instabilité** : de petites variations dans l'image LR peuvent produire des changements importants dans la reconstruction. Enfin, le **manque d'information** : des détails haute fréquence sont irrémédiablement perdus lors de la dégradation et ne peuvent être récupérés sans hypothèses supplémentaires.

Formellement, le problème de super-résolution consiste à trouver :

$$\hat{I}_{HR} = \arg \max_{I_{HR}} P(I_{HR}|I_{LR}) \quad (1.5)$$

Cette formulation bayésienne peut être réécrite selon le théorème de Bayes :

$$\hat{I}_{HR} = \arg \max_{I_{HR}} \frac{P(I_{LR}|I_{HR})P(I_{HR})}{P(I_{LR})} \quad (1.6)$$

où $P(I_{LR}|I_{HR})$ est le modèle de vraisemblance (processus de dégradation) et $P(I_{HR})$ le prior sur les images HR naturelles.

1.2.3 Approches classiques vs apprentissage profond

Interpolation bicubique

L'interpolation bicubique est la méthode la plus simple de super-résolution. Elle estime la valeur d'un pixel dans l'image HR en calculant une combinaison pondérée des 16 pixels voisins (grille 4×4) dans l'image LR. Bien que rapide, cette méthode produit des images floues et n'hallucine aucun détail haute fréquence.

Méthodes basées sur dictionnaires

Ces approches (ex : *sparse coding*) apprennent un dictionnaire de paires de patches LR-HR. Durant l'inférence, chaque patch LR est décomposé sur le dictionnaire LR, puis reconstruit en utilisant les coefficients obtenus avec le dictionnaire HR correspondant. Bien que plus performantes que l'interpolation, ces méthodes restent limitées par la capacité du dictionnaire et sont coûteuses en calcul.

Limites des approches traditionnelles

Les méthodes classiques reposent sur des priors manuellement définis (régularisation totale variation, statistiques naturelles d'images) qui ne capturent qu'imparfaitement la complexité des images réelles. Elles échouent notamment à halluciner de manière cohérente les détails haute fréquence perdus lors de la dégradation.

1.2.4 Super-résolution par apprentissage profond

SRCNN (2014)

Super-Resolution Convolutional Neural Network est la première approche exploitant les CNN pour la super-résolution [15]. L'architecture, simple mais efficace, se compose de trois étapes successives : l'extraction de patches et leur représentation, le mapping non-linéaire des caractéristiques extraites, puis la reconstruction de l'image haute résolution. Malgré sa simplicité, SRCNN surpasse significativement les méthodes traditionnelles en apprenant directement la fonction de mapping $LR \rightarrow HR$.

VDSR (2016)

Very Deep Super-Resolution exploite des connexions résiduelles et une architecture profonde (20 couches) pour améliorer les performances [16]. Au lieu de prédire directement I_{HR} , VDSR apprend le résidu $R = I_{HR} - I_{LR}$, facilitant l’optimisation.

ESRGAN (2018)

Enhanced Super-Resolution Generative Adversarial Network introduit plusieurs innovations majeures [9]. L’architecture repose sur les **blocs RRDB** (*Residual in Residual Dense Block*), qui sont des blocs résiduels enrichis de connexions denses permettant une meilleure propagation du gradient. Elle intègre également un **discriminateur relativiste** qui évalue non pas si une image est réelle ou générée, mais la probabilité qu’elle soit plus réaliste qu’une autre. Enfin, la **perte perceptuelle** est calculée à partir des caractéristiques de VGG avant activation plutôt qu’après, ce qui améliore sensiblement la qualité visuelle des résultats. ESRGAN produit ainsi des images perceptuellement plus réalistes que les approches basées uniquement sur des pertes pixel-wise telles que la MSE ou la MAE.

1.2.5 Réseaux antagonistes génératifs (GAN)

Principe des GAN

Les GAN, introduits par Goodfellow et al. [13], reposent sur l’interaction entre deux réseaux antagonistes entraînés conjointement. Le **générateur** G apprend à produire des données réalistes à partir de bruit ou d’images basse résolution, tandis que le **discriminateur** D cherche à distinguer les données réelles des données générées. Cette compétition est formalisée par le jeu minimax suivant :

$$\min_G \max_D \mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))] \quad (1.7)$$

où x représente les données réelles et z le bruit d’entrée.

Application à la super-résolution

Dans le contexte de la super-résolution, le générateur G prend en entrée une image LR et produit une image SR, tandis que le discriminateur D essaie de distinguer les

images SR générées des vraies images HR. Cette approche adversariale permet de générer des images perceptuellement réalistes avec des détails haute fréquence cohérents.

1.3 Problématique

1.3.1 Défis de la super-résolution faciale

La super-résolution faciale présente des défis spécifiques par rapport à la super-résolution d'images génériques. La **préservation de l'identité** constitue le premier enjeu majeur : la reconstruction doit maintenir les caractéristiques qui permettent de reconnaître la personne. S'y ajoute la nécessité de restituer les **détails fins** propres aux visages, tels que la texture de la peau, les cheveux ou encore les rides, qui doivent être reconstruits de manière cohérente. Par ailleurs, la **structure géométrique** du visage — c'est-à-dire la position relative des yeux, du nez et de la bouche — doit être scrupuleusement respectée. Enfin, le modèle doit faire preuve de robustesse face aux **variations de pose et d'éclairage** inhérentes aux conditions réelles d'acquisition.

1.3.2 Impact des masques faciaux

La pandémie de COVID-19 a introduit une problématique nouvelle : la présence systématique de masques faciaux dans de nombreuses images. Ces masques occultent entre 30 et 40% du visage, notamment le nez, la bouche et les joues, rendant ainsi inutilisables les priors faciaux traditionnels fondés sur des landmarks incomplets. Leur présence impose une reconstruction par hallucination des régions cachées et complique considérablement la préservation de l'identité faciale. Cette problématique n'est pas adéquatement traitée par les méthodes existantes de super-résolution faciale, créant un gap dans la littérature scientifique.

1.3.3 Formulation du problème

La problématique centrale de ce travail peut être formulée ainsi :

Comment reconstruire des images faciales haute résolution à partir d'images basse résolution portant des masques faciaux, tout en préservant l'identité de la personne et les détails structurels du visage ?

Cette question soulève plusieurs défis techniques interdépendants. Le premier relève du **dual-task learning** : il est nécessaire de traiter simultanément la suppression du masque et la super-résolution, deux tâches distinctes mais étroitement liées. Le deuxième défi tient au **manque d'information** : les régions occultées doivent être reconstruites sans aucune donnée directe, ce qui requiert une hallucination cohérente fondée sur le contexte visible. Le troisième enjeu concerne la **préservation de l'identité** : la reconstruction doit conserver les traits caractéristiques de la personne afin de permettre une reconnaissance faciale ultérieure. Enfin, le **guidage structurel** pose la question de savoir comment orienter efficacement la reconstruction en l'absence de priors faciaux complets, pour que la géométrie du visage demeure cohérente.

1.3.4 Problème traité

Le problème traité dans ce projet peut être formalisé comme suit. En **entrée**, le modèle reçoit une image faciale basse résolution (32×32) portant un masque facial. En **sortie**, il produit une image faciale haute résolution (128×128) sans masque, en préservant l'identité de la personne. Ce traitement est soumis à plusieurs **contraintes** : un facteur de super-résolution de $\times 4$, le maintien de l'identité faciale, une reconstruction cohérente des régions occultées, et la restitution de détails haute fréquence réalistes.

1.4 Solution proposée

Pour adresser cette problématique, nous proposons MEFSR-GAN (*Masked Edge-guided Face Super-Resolution GAN*), une architecture modulaire composée de trois modules principaux :




FIG. 1.1 : Architecture générale proposée de MEFSR-GAN

1.4.1 Approche progressive

Nous adoptons une stratégie de développement progressive en trois versions successives. La **version 1.0** constitue une architecture simple reposant sur une fusion basique et ResNet [19] pour la super-résolution. La **version 2.0** enrichit ce socle par l’ajout d’un mécanisme d’attention et des blocs RRDB issus d’ESRGAN [9]. Enfin, la **version 3.0** intègre un discriminateur GAN [13] pour renforcer le réalisme perceptuel des reconstructions. Cette approche incrémentale permet une étude d’ablation claire de la contribution de chaque composant.

1.5 Objectifs du travail

1.5.1 Objectifs fonctionnels

Ce projet poursuit cinq objectifs fonctionnels. Il s’agit d’abord de **transformer des images faciales basse résolution en images haute résolution** en améliorant la résolution d’un facteur $\times 4$ ($32 \times 32 \rightarrow 128 \times 128$). Le deuxième objectif est de **supprimer les masques faciaux** en reconstruisant les régions occultées de manière cohérente et réaliste. Il convient également de **préserver l’identité du visage reconstruit** en maintenant les caractéristiques permettant la reconnaissance faciale [20]. Le quatrième objectif vise à **restaurer les détails fins**, notamment la texture de la peau, les cheveux et autres éléments haute fréquence. Enfin, le modèle doit **minimiser les artefacts de reconstruction** en évitant les distorsions, le flou excessif et les incohérences visuelles.

1.5.2 Objectifs quantitatifs

Sur le plan quantitatif, les performances visées sont un PSNR supérieur ou égal à 25 dB et un SSIM supérieur ou égal à 0,80, mesurés sur le jeu de test CelebA-HQ masqué. Ces seuils sont établis en référence à trois éléments complémentaires.

D’abord, la baseline bicubique sur notre configuration ($32 \times 32 \rightarrow 128 \times 128$ avec masque) atteint 23,00 dB : un objectif de 25 dB représente un gain de +2 dB, seuil généralement reconnu comme perceptiblement significatif en super-résolution d’images [15].

Ensuite, les méthodes de l’état de l’art en super-résolution faciale à facteur $\times 4$ — présentées en détail au chapitre 2 — se situent typiquement dans la plage 24–30 dB selon le dataset et la présence ou non d’occlusions. Notre cible de 25 dB se place ainsi dans une plage réaliste et compétitive, compte tenu de notre configuration plus difficile

(entrée 32×32 masquée) et de nos contraintes de ressources (dataset de 24 678 paires, GPU Kaggle).

Enfin, le seuil $\text{SSIM} \geq 0,80$ correspond à la valeur communément considérée comme indicatrice d’une bonne qualité structurelle en super-résolution faciale [21].

1.5.3 Objectifs méthodologiques

D’un point de vue méthodologique, ce travail vise à concevoir une architecture modulaire facilitant l’étude d’ablation, à implémenter et entraîner des modèles progressivement plus complexes, à comparer rigoureusement les résultats avec l’état de l’art existant, et à documenter l’ensemble du processus de développement pour en assurer la reproductibilité.

1.6 Applications existantes

La super-résolution faciale trouve des applications dans de nombreux domaines : la reconnaissance faciale et la vidéosurveillance (amélioration d’images capturées à distance ou en basse résolution [20]), la visioconférence (amélioration de la qualité vidéo en temps réel), l’analyse des expressions faciales, ainsi que la restauration d’images et de films anciens. Dans le contexte post-pandémique, la gestion des visages masqués constitue un enjeu supplémentaire pour ces applications.

Conclusion

Ce chapitre a posé les fondements nécessaires à la compréhension de MEFSR-GAN : principes de l’apprentissage profond, architectures CNN et GAN, formalisation du problème de super-résolution mal posé, et défis spécifiques aux visages masqués. La problématique est clairement établie — reconstruire en $\times 4$ un visage masqué ($32 \times 32 \rightarrow 128 \times 128$) tout en préservant l’identité — et les objectifs quantitatifs fixés ($\text{PSNR} \geq 25$ dB, $\text{SSIM} \geq 0,80$), dont la justification est détaillée en section 1.5.2.

Chapitre 2

État de l’art

Introduction

Plusieurs méthodes de super-résolution faciale ont été proposées dans la littérature scientifique. Avec l’apparition des masques faciaux, ce domaine a évolué vers des approches capables de gérer simultanément la basse résolution et les occlusions. Parmi ces méthodes, on trouve notamment : JDSR-GAN [5], FSRNet [4], SANet [6], EIPNet [2], FCSR-GAN [3], SLNet [7] et EFBPGAN [1].

2.1 Revue des travaux existants

2.1.1 JDSR-GAN (Joint Denoising and Super-Resolution GAN)

La méthode JDSR-GAN proposée dans [5] combine la reconstruction d’image et l’apprentissage conjoint afin d’améliorer la qualité des visages masqués.

L’article intitulé *JDSR-GAN : Constructing An Efficient Joint Learning Network for Masked Face Super-Resolution*, publié en 2023 dans la revue IEEE Transactions on Multimedia, propose une approche unifiée pour la reconstruction de visages masqués en basse résolution. Les auteurs s’intéressent à un contexte devenu particulièrement pertinent avec la généralisation du port du masque, notamment dans les systèmes de vidéosurveillance, où les images acquises sont souvent simultanément dégradées et partiellement occultées.

Contrairement aux méthodes existantes qui traitent séparément le débruitage et la super-résolution, l’article introduit un modèle d’apprentissage conjoint fondé sur une architecture générative antagoniste (GAN) [13], dénommée JDSR-GAN, capable de ré-

soudre ces deux tâches dans un cadre unique et cohérent.

L'objectif principal est de reconstruire une image faciale haute résolution sans masque à partir d'une image d'entrée de faible qualité, affectée à la fois par du bruit et par une occlusion due au masque. L'originalité du travail réside dans l'intégration conjointe des deux processus au sein d'un modèle entraîné de bout en bout.




FIG. 2.1 : Architecture du réseau proposé JDSR-GAN. Source : extrait de [5].

Problématique traitée

Dans les applications réelles, notamment en vidéosurveillance, les visages capturés présentent deux dégradations majeures : une faible résolution due aux conditions d'acquisition, et une occlusion partielle liée au port du masque. Les approches traditionnelles traitent ces problèmes de manière séquentielle, en appliquant d'abord un algorithme de débruitage, puis un modèle de super-résolution. Toutefois, cette stratégie ne permet pas d'exploiter les dépendances structurelles entre les deux tâches et peut conduire à une perte d'informations importantes. La problématique centrale de l'article consiste donc à concevoir un modèle unique capable de réaliser simultanément le débruitage et la super-résolution, tout en préservant l'identité faciale et les détails texturaux. Il s'agit d'un problème complexe, car la reconstruction doit être fidèle à la structure géométrique du visage et cohérente avec les informations sémantiques perdues dans la zone masquée.

Méthodologie utilisée

La méthodologie repose sur une architecture GAN composée d'un générateur et d'un discriminateur. Le générateur est structuré en deux modules successifs : un module de débruitage et un module de super-résolution faciale. Le discriminateur, quant à lui, est inspiré de WGAN-GP afin d'assurer une convergence stable et de renforcer la qualité perceptuelle des images générées. L'apprentissage est formulé comme un problème multi-tâches. Plusieurs fonctions de perte sont intégrées afin de contraindre différents aspects de la reconstruction : fidélité pixel à pixel, cohérence perceptuelle, préservation du

Le second module assure la super-résolution faciale. Il est structuré autour d'un réseau de reconstruction grossière, d'un module d'estimation de prior géométrique (incluant cartes de segmentation faciale et points de repère), ainsi que d'un encodeur-décodeur permettant de fusionner les caractéristiques visuelles et les informations géométriques. L'intégration de mécanismes d'attention et de blocs résiduels [19] favorise la capture conjointe des caractéristiques locales et globales.




FIG. 2.3 : Architecture du second module, dédié à la super-résolution faciale. Source : extrait de [5].

Le discriminateur, basé sur le principe du Wasserstein GAN avec pénalisation du gradient [12], évalue la différence entre les images reconstruites et les images réelles haute résolution. Cette composante adversariale permet d'améliorer la qualité perceptuelle et la texture fine des images générées. L'ensemble du modèle est entraîné de manière end-to-end, ce qui permet une interaction directe entre les deux modules et une optimisation globale cohérente.

Résultats obtenus

Les performances sont évaluées à l'aide des métriques PSNR, SSIM et FID. Sur le dataset CelebA avec un facteur d'échelle $4\times$, JDSR-GAN atteint un PSNR de 29.18 dB et un SSIM de 0.8553, surpassant les méthodes comparées telles que CBD+DRN [25], CBD+FSRGAN [4] et CBD+DICGAN [26]. Le FID obtenu est également inférieur, indiquant une meilleure qualité perceptuelle. Pour un facteur d'échelle $8\times$, le modèle maintient des performances supérieures avec un PSNR de 26.45 dB et un SSIM de 0.7633, démontrant sa robustesse face à des dégradations sévères.

Points forts et limites

Parmi les points forts de cette approche figurent l'intégration conjointe du débruitage et de la super-résolution dans un cadre unifié, l'utilisation efficace de l'apprentissage multi-tâches et l'introduction de contraintes d'identité et de prior géométrique, qui

renforcent la fidélité structurelle des visages reconstruits. Les résultats expérimentaux montrent une amélioration significative tant sur le plan quantitatif que qualitatif. Cependant, l’architecture demeure relativement complexe et repose sur un ensemble important de fonctions de perte nécessitant un réglage précis des coefficients. De plus, les masques utilisés dans les expériences principales sont générés artificiellement, ce qui peut limiter la représentativité complète des conditions réelles malgré les tests supplémentaires effectués sur des images collectées en ligne. En conclusion, JDSR-GAN constitue une contribution significative dans le domaine de la super-résolution faciale sous occlusion, en démontrant que l’apprentissage conjoint de tâches complémentaires permet d’obtenir des reconstructions plus fidèles et visuellement cohérentes que les approches séquentielles traditionnelles.

2.1.2 EFBPGAN (Edge Fusion Back Projection GAN)

La méthode EFBPGAN proposée dans [1] s’inscrit dans la lignée des travaux exploitant les priors génératifs pour la super-résolution faciale à très grande échelle, notamment pour des facteurs d’échelle de $16\times$.

L’article intitulé *Edge fusion back projection GAN for large scale face super resolution*, publié en 2024 dans le *Journal of Visual Communication and Image Representation*, propose une architecture novatrice dénommée EFBPGAN (Edge Fusion Back Projection Generative Adversarial Network). Les auteurs, Xi Cheng et Wan-Chi Siu, s’intéressent à un problème particulièrement difficile : la reconstruction de visages haute résolution à partir d’images d’entrée de très faible résolution, où seulement 0,4% des pixels de la référence sont disponibles. Ils constatent que les méthodes existantes optimisant directement la distance au niveau pixel ou feature tendent à produire des résultats flous et surlissés, manquant cruellement de détails haute fréquence essentiels à la perception des visages.

Problématique traitée

La super-résolution faciale à grande échelle ($8\times$, $16\times$ et plus) constitue un défi majeur car la restitution doit s’effectuer à partir d’une quantité d’information extrêmement réduite. Les approches par régression CNN classiques [15], bien qu’offrant de bons scores PSNR, souffrent d’un problème de surlissage car elles génèrent en moyenne les solutions possibles, ne se trouvant pas sur la même variété que les images réelles. L’utilisation de GANs [13], et notamment de priors génératifs pré-entraînés comme StyleGAN [27], permet d’améliorer la qualité perceptuelle mais introduit des distorsions et des artefacts, tout en peinant à préserver l’identité et la structure spatiale du visage source. La problématique centrale de l’article consiste donc à concevoir un modèle capable de générer des visages réalistes à très haute résolution tout en conservant la fidélité structurelle et l’identité de

l’image basse résolution d’entrée, en supprimant les distorsions typiques des approches par prior génératif.

Méthodologie utilisée

La méthodologie repose sur une architecture en deux étapes intégrant un prior génératif StyleGAN2 [28], combiné à des modules de fusion d’arêtes (Edge Fusion), de fusion spatiale attentive (Spatial Fusion) et un mécanisme de back-projection conjoint. Dans un premier temps, le réseau extrait les caractéristiques bas niveau de l’image LR via un réseau d’extraction de caractéristiques (FEN) basé sur des blocs résiduels denses avec mise à l’échelle apprenable (SRDB). Parallèlement, un réseau d’extraction d’arêtes (EEN) récupère l’information structurelle des contours faciaux. Ces deux informations sont encodées puis fusionnées en un vecteur latent qui contrôle le générateur StyleGAN2. Afin de préserver la cohérence spatiale et les attributs faciaux, un module de fusion spatiale attentive (ASFB) recalibre dynamiquement les caractéristiques provenant de l’encodeur et celles générées par StyleGAN. Enfin, un mécanisme de back-projection conjoint (image + arêtes) en deux étapes permet de supprimer les distorsions : la première étape génère un résultat grossier, puis la différence entre la version dégradée de ce résultat et l’entrée LR est calculée et ré-injectée dans la deuxième étape pour affiner la reconstruction. L’apprentissage est supervisé par une combinaison de perte pixel (MSE), de perte perceptuelle (VGG16) [18] et de perte adversariale.

Dataset utilisé

Les expérimentations sont menées principalement sur le dataset FFHQ (Flickr-Faces-High-Quality) [27], qui contient 70 000 images faciales de très haute qualité (1024×1024), utilisées pour l’entraînement avec un facteur d’échelle de $16\times$. Les images basse résolution sont obtenues par sous-échantillonnage bicubique. Pour la phase de test et d’évaluation comparative, les auteurs utilisent 100 images sélectionnées du dataset CelebA-HQ [29], présentant la même résolution que FFHQ, afin de restaurer des visages de 64×64 vers 1024×1024 . Cette séparation entre dataset d’entraînement et de test permet d’évaluer la capacité de généralisation du modèle sur des données distinctes.

Architecture proposée

L’architecture globale se décompose en deux étapes principales partageant une structure commune. La première étape, dite de super-résolution grossière, génère un visage haute résolution initial. La deuxième étape, de back-projection et raffinement, corrige les distorsions. Chaque étape comprend : (1) un Réseau d’Extraction de Caractéristiques

(FEN) utilisant des SRDB avec des connexions résiduelles [19] et denses et un facteur de mise à l'échelle apprenable ; (2) un Réseau d'Extraction d'Arêtes (EEN) doté de filtres spéciaux ; (3) des encodeurs d'image et d'arêtes qui projettent les caractéristiques dans l'espace latent de StyleGAN2 ; (4) le module de Fusion d'Arêtes qui combine les vecteurs latents image et contour ; (5) le module de Fusion Spatiale Attentive (ASFB) qui intègre les caractéristiques de l'encodeur LR avec celles des blocs StyleGAN via un mécanisme de recalibration par blocs SE et SK ; (6) un générateur StyleGAN2 pré-entraîné, figé, qui produit les caractéristiques haute qualité ; et (7) un décodeur qui reconstruit l'image finale. Le back-projection conjoint calcule non seulement la différence entre l'image SR dégradée et l'entrée LR, mais également la différence au niveau des arêtes, ce qui renforce la conservation de la structure géométrique.




FIG. 2.4 : Architecture de la méthode EFBPGAN. Source : extrait de [1].

Résultats obtenus

Les performances sont évaluées à l'aide des métriques PSNR, LPIPS, FID et NIQE. Sur le dataset CelebA-HQ avec un facteur d'échelle $16\times$, EFBPGAN atteint un PSNR de 27,05 dB, un LPIPS de 0,2116, un FID de 41,553 et un NIQE de 4,363, surpassant les méthodes comparées telles que RCAN [30], Real-ESRGAN [31], PULSE [32], GPEN [33], GFPGAN [34] et GLEAN [35]. Comparativement, les méthodes orientées fidélité comme RCAN obtiennent un meilleur PSNR (27,66 dB) mais des scores perceptuels très faibles (LPIPS 0,3733, FID 113,82), tandis que les méthodes par inversion GAN comme PULSE affichent un bon NIQE (3,91) mais un PSNR très faible (21,31 dB) et une incapacité à préserver l'identité. L'étude d'ablation montre que le module de fusion d'arêtes améliore significativement le PSNR (de 26,61 à 27,05 dB) et les métriques perceptuelles. De même, la fusion spatiale attentive et le back-projection conjoint (image + arêtes) contribuent de manière essentielle à la qualité finale, confirmant que chaque module apporte une valeur ajoutée mesurable.

Points forts et limites

Parmi les points forts figurent l’intégration efficace du prior génératif StyleGAN2 avec des mécanismes de conservation de la structure (edge fusion et back-projection), permettant d’obtenir des résultats à la fois réalistes et fidèles à l’entrée. L’architecture offre un excellent équilibre entre métriques de fidélité et métriques perceptuelles, dépassant les approches existantes sur les critères visuels tout en maintenant un PSNR compétitif. La conception modulaire permet d’améliorer progressivement la qualité via le mécanisme de back-projection en deux étapes. Cependant, l’architecture demeure relativement complexe et repose sur un générateur StyleGAN2 pré-entraîné et figé, ce qui limite l’adaptabilité du modèle à d’autres domaines de visages ou à des distributions différentes. De plus, les expérimentations sont limitées à des images de bonne qualité (FFHQ, CelebA-HQ) et ne testent pas explicitement la robustesse face à des dégradations réelles complexes (bruit, flou, compression). En conclusion, EFBPGAN constitue une avancée significative pour la super-résolution faciale à très grande échelle, démontrant que la combinaison de priors génératifs et de contraintes structurelles explicites permet de surmonter les limitations des approches par régression ou par GAN seules.

2.1.3 EIPNet (Edge and Identity Preserving Network)

La méthode EIPNet proposée dans [2] introduit une approche légère et efficace pour la super-résolution faciale, en mettant l’accent sur la préservation des contours et de l’identité.

L’article intitulé *Edge and Identity Preserving Network for Face Super-Resolution*, publié en 2021 dans la revue *Neurocomputing*, propose un réseau dénommé EIPNet (Edge and Identity Preserving Network). Les auteurs, Jonghyun Kim et collaborateurs, s’intéressent à la restauration de composants faciaux dégradés lors du processus de super-résolution, notamment les yeux, le nez et la bouche, qui subissent des distorsions importantes dans les méthodes existantes. Contrairement aux approches lourdes exploitant des réseaux de détection de points de repère faciaux coûteux en calcul et nécessitant des annotations supplémentaires, cette méthode propose une solution allégée intégrant un bloc d’arêtes minimaliste et une fonction de perte d’identité innovante.

Problématique traitée

Dans les systèmes de super-résolution faciale, la distorsion des composants faciaux constitue un obstacle majeur pour les applications de sécurité et de reconnaissance. Les méthodes existantes utilisent souvent des priors faciaux complexes (landmarks, heatmaps)

qui nécessitent des réseaux profonds supplémentaires, des temps d’entraînement prolongés et des annotations coûteuses, difficiles à obtenir dans des scénarios réels. De plus, la simple utilisation de fonctions de perte pixelwise (L1/L2) tend à produire des images sur-lissées sans identité stable. La problématique centrale consiste donc à concevoir un réseau léger capable de restaurer fidèlement les détails structurels des visages tout en préservant l’identité personnelle, sans dépendre de labels de landmarks ou de guides externes.

Méthodologie utilisée

La méthodologie repose sur trois contributions principales. Premièrement, un *Edge Block* ultra-léger, composé d’une simple couche de convolution 1×1 et d’une couche de *average pooling*, est intégré après chaque bloc de transposition convolutive à différentes échelles. Ce bloc extrait les composantes haute fréquence par soustraction des features lissées des features originales, fournissant progressivement l’information de contour au réseau. Deuxièmement, une fonction de perte d’identité est définie en utilisant la divergence de Jensen-Shannon (JS) entre les vecteurs encodés de classe extraits par un réseau InceptionV1 pré-entraîné sur VGGFace2 [36], permettant de comparer les distributions d’identité entre l’image SR et l’image cible sans nécessiter de labels d’identité explicites. Troisièmement, une erreur luminance-chrominance (LCE) est introduite en convertissant les images de l’espace RGB vers YUV, permettant d’optimiser séparément la brillance et la couleur et de réduire les distorsions chromatiques. L’ensemble est entraîné avec une perte de reconstruction RGB, la perte d’arêtes, la LCE, la perte d’identité et une perte adversariale (GAN) [13].

Dataset utilisé

Les expérimentations sont conduites sur deux datasets publics largement utilisés : CelebA [8] et VGGFace2 [36]. Pour CelebA, les auteurs utilisent 162 770 images alignées pour l’entraînement et 19 962 images pour le test. Ils utilisent également les images non alignées de CelebA. Pour VGGFace2, 135 516 images d’entraînement et 33 880 images de test sont employées. Les images sont recadrées et redimensionnées à 128×128 pour l’image haute résolution, puis sous-échantillonnées par facteur $\times 8$ pour obtenir des entrées de 16×16 pixels. Afin d’évaluer spécifiquement la qualité des régions faciales, les auteurs introduisent les métriques FR-PSNR et FR-SSIM, qui recadrent automatiquement la région faciale via un détecteur de visages avant calcul, éliminant ainsi l’influence du bruit de fond.

Architecture proposée

L'architecture EIPNet est un réseau encodeur-décodeur léger composé de trois blocs résiduels, trois blocs de transposition convolutive et trois *Edge Blocks*. L'entrée de 16×16 passe d'abord par une convolution initiale de 512 canaux, suivie de blocs résiduels avec ReLU. Chaque bloc de transposition convolutive effectue un suréchantillonnage $2 \times$ (passant successivement à 32×32 , 64×64 puis 128×128). Après chaque transposition, un *Edge Block* extrait et concatène l'information de contour. Le discriminateur adopté est une architecture classique avec des convolutions LeakyReLU et deux couches fully-connected. L'ensemble est conçu pour être efficace : le modèle atteint 215 images par seconde (FPS) sur une GPU GTX 1080Ti pour la reconstruction 128×128 .




FIG. 2.5 : Architecture de la méthode EIPNet. Source : extrait de [2].

Résultats obtenus

Sur CelebA ($\times 8$), EIPNet atteint 25,08 dB en PSNR et 0,7429 en SSIM, surpassant FSRGAN [4] (22,84 dB / 0,6665), [37] (23,19 dB), GLFSR [38] (24,19 dB), SiGAN [39] (24,17 dB), IDN [40] (24,28 dB) et [41] (24,41 dB). En termes de préservation d'identité, le taux d'acceptation vrai (TAR) atteint 64% contre 58% sans la perte d'identité, démontrant l'efficacité de cette contrainte. Sur VGGFace2, les performances restent compétitives avec 24,56 dB en PSNR. L'étude d'ablation montre que le bloc d'arêtes multi-échelles améliore considérablement les résultats (PSNR de 23,11 à 24,74 dB sur CelebA), et que la combinaison des trois échelles ($2 \times$, $4 \times$, $8 \times$) offre les meilleurs résultats. La perte LCE en YUV améliore également la qualité par rapport à une perte RGB seule (PSNR 23,83 contre 23,11 dB). Enfin, l'évaluation BRISQUE (NR-IQA) montre que la version avec GAN obtient le meilleur score (32,55), inférieur même à l'image ground-truth (35,78), indiquant une excellente qualité perceptuelle.

Points forts et limites

Les points forts d'EIPNet résident dans sa légèreté et son efficacité computationnelle, associées à des performances de pointe. Le *Edge Block* minimaliste démontre qu'un simple mécanisme de soustraction de features lissées peut extraire efficacement les contours sans surcoût majeur. La perte d'identité par divergence JS offre une solution élégante à la préservation de l'identité sans labels supplémentaires. La LCE permet une meilleure gestion des couleurs. Cependant, la méthode ne traite pas explicitement les cas d'occlusion faciale (masques, lunettes importantes) et repose sur un discriminateur standard qui peut parfois introduire des artéfacts dans les régions de détail. De plus, bien que le modèle soit léger, sa complexité computationnelle n'est pas la plus faible de l'état de l'art (11,91M de paramètres contre 0,68M pour IDN). En conclusion, EIPNet démontre qu'une architecture soigneusement conçue avec des modules légers et des fonctions de perte spécialisées peut atteindre des performances comparables ou supérieures aux méthodes lourdes basées sur des priors faciaux explicites.

2.1.4 FCSR-GAN (Joint Face Completion and Super-Resolution GAN)

La méthode FCSR-GAN proposée dans [3] aborde simultanément deux dégradations majeures des images faciales : la basse résolution et l'occlusion.

L'article intitulé *FCSR-GAN : Joint Face Completion and Super-resolution via Multi-task Learning*, publié en 2019 dans les *IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, propose une approche unifiée pour la restauration conjointe de visages basse résolution et partiellement occultés. Les auteurs, Jiancheng Cai et collaborateurs, s'intéressent à un scénario critique en vidéosurveillance où les visages capturés présentent simultanément une faible résolution et des occlusions (par exemple par des masques, des objets ou des zones manquantes). Ils démontrent que l'application séquentielle d'une méthode de completion puis de super-résolution (ou inversement) introduit des artéfacts importants car ces deux problèmes sont traités comme indépendants alors qu'ils partagent des relations structurelles profondes.

Problématique traitée

Les approches existantes de restauration d'images faciales traitent généralement un seul type de dégradation par modèle : soit la completion (restauration de régions manquantes), soit la super-résolution (restauration de la haute résolution). Dans les scénarios réels, notamment en vidéosurveillance, un visage peut être simultanément de basse

résolution et partiellement occulté. Une approche séquentielle (completion puis super-résolution ou l’inverse) s’avère sous-optimale car elle traite les deux problèmes de manière indépendante, ignorant les relations internes entre la structure globale du visage et ses détails texturaux. De plus, appliquer la completion sur une image basse résolution ou la super-résolution sur une image avec zones manquantes génère des artéfacts visuels importants. La problématique consiste donc à concevoir un modèle unique, entraînable de bout en bout, capable de réaliser conjointement la completion et la super-résolution dans un cadre de multi-task learning.

Méthodologie utilisée

La méthodologie repose sur une architecture GAN [13] avec un générateur composé de deux modules : un module de completion faciale (FC) et un module de super-résolution faciale (SR). Le module FC prend l’image LR avec occlusion et restaure d’abord une image LR sans occlusion. Le module SR prend ensuite cette image complétée pour générer la version haute résolution finale. L’apprentissage se déroule en deux étapes : d’abord un pré-entraînement du module FC avec des pertes de completion (perte de style [42], perceptuelle [14], pixel et lissage), puis un entraînement end-to-end de l’ensemble du réseau avec des pertes supplémentaires de super-résolution (perte adversariale, prior facial, perceptuelle, pixel et lissage). Le discriminateur combine une perte adversariale classique et un *face prior loss* qui pénalise la différence entre les heatmaps de landmarks et les cartes de parsing prédites et celles du ground-truth, assurant ainsi une structure faciale topologiquement correcte. Cette stratégie à deux étapes permet de stabiliser l’entraînement et d’obtenir des résultats de haute qualité.

Dataset utilisé

Les expérimentations sont menées sur les datasets publics CelebA [8] et Helen [23]. Pour CelebA, les auteurs utilisent les images pour l’entraînement et l’évaluation, en recadrant les régions faciales sans alignment préalable et en redimensionnant à 128×128 pour l’HR. Les images LR sont obtenues par sous-échantillonnage avec des facteurs allant jusqu’à $\times 8$. Pour Helen, les 2 330 images sont utilisées, dont les 50 dernières pour le test. Les masques d’occlusion sont générés artificiellement pour simuler des conditions réalistes. L’évaluation est réalisée avec les métriques classiques PSNR et SSIM, ainsi qu’une évaluation qualitative des capacités de généralisation cross-dataset.

Architecture proposée

L'architecture FCSR-GAN comprend un générateur avec un module de completion faciale (FC) et un module de super-résolution (SR). Le module FC peut être instancié par des méthodes existantes comme GFC ou PConv, tandis que le module SR peut utiliser SRResNet ou FSRNet, offrant ainsi quatre combinaisons possibles. Le discriminateur adopte une structure Patch-GAN classique [10]. L'originalité réside dans la conception des fonctions de perte : la perte de style (Gram matrix) assure la cohérence stylistique entre la région restaurée et la région non occultée ; la perte de lissage réduit les distorsions chromatiques aux frontières des zones occluses ; et le *face prior loss* utilise un réseau auxiliaire prédictif de landmarks et de cartes de parsing pour garantir la structure sémantique du visage. Cette architecture modulaire permet d'effectuer la completion jusqu'à $\times 8$ de super-résolution simultanément.




FIG. 2.6 : Architecture de la méthode FCSR-GAN. Source : extrait de [3].

Résultats obtenus

Les résultats quantitatifs montrent que FCSR-GAN surpasse significativement les approches séquentielles (application de GFC [43] puis SRResNet [44], ou inversement). La meilleure combinaison (PConv + FSRNet) atteint **24,75 dB en PSNR** et **0,761 en MSSIM** sur CelebA (facteur $\times 4$). Les images restaurées par les méthodes séquentielles présentent des artéfacts visuels marqués et des structures faciales incorrectes, tandis que FCSR-GAN produit des visages réalistes avec des détails fidèles et une occlusion correctement supprimée. L'approche démontre également une bonne capacité de généralisation

cross-dataset (entraînement sur CelebA, test sur Helen). L’évaluation sur la reconnaissance faciale montre que FCSR-GAN améliore les performances d’identification lorsque les images d’entrée sont de basse résolution et occluses, validant son utilité pratique pour les systèmes de sécurité.

Points forts et limites

Les points forts de FCSR-GAN incluent son approche unifiée traitant deux dégradations complexes simultanément via le multi-task learning, sa stratégie d’entraînement en deux étapes qui stabilise efficacement l’apprentissage, et son *face prior loss* qui garantit la cohérence structurelle des composants faciaux. La modularité du générateur permet d’intégrer différentes méthodes de completion et de super-résolution selon les besoins. Cependant, la méthode dépend de la qualité des modules FC et SR choisis : si ces composants de base sont limités, les résultats finaux en pâtissent. De plus, les occlusions testées sont principalement simulées artificiellement, et la méthode n’est pas spécifiquement adaptée à des occlusions très larges ou à des variabilités extrêmes de pose. En conclusion, FCSR-GAN constitue une contribution significative pour la restauration faciale dans des conditions réelles complexes, prouvant que l’apprentissage conjoint de tâches complémentaires permet de restaurer des informations autrement irrécupérables par des approches séquentielles.

2.1.5 FSRNet (Face Super-Resolution Network)

La méthode FSRNet proposée dans [4] représente une avancée majeure dans l’exploitation des priors géométriques faciaux pour la super-résolution end-to-end.

L’article intitulé *FSRNet : End-to-End Learning Face Super-Resolution with Facial Priors*, présenté en 2018 lors de la conférence CVPR, propose le premier réseau de super-résolution faciale entièrement entraînable de bout en bout intégrant simultanément des priors géométriques (heatmaps de landmarks et cartes de parsing). Les auteurs, Yu Chen et collaborateurs, s’attaquent à la reconstruction de visages de très basse résolution (16×16 pixels) avec un facteur d’échelle de $\times 8$, sans nécessiter d’alignement préalable des visages. Contrairement aux méthodes multi-étapes existantes, FSRNet apprend directement la solution globale dans un seul réseau unifié.

Problématique traitée

La super-résolution faciale extrême (facteur $\times 8$) à partir de visages très petits (16×16) est un problème hautement sous-déterminé. Les méthodes génériques de super-

résolution d’images naturelles, bien que puissantes, ignorent les connaissances a priori spécifiques aux visages (forme des yeux, position du nez, structure du menton) qui pourraient guider la reconstruction. Les méthodes faciales existantes exploitant ces priors le font généralement en plusieurs étapes séquentielles (d’abord estimer les landmarks, puis reconstruire), ce qui est inconfortable, lent et suboptimal. La problématique centrale consiste à concevoir un réseau end-to-end qui estime automatiquement les priors géométriques faciaux et les utilise conjointement pour guider la reconstruction haute résolution, tout en étant robuste aux visages non alignés.

Méthodologie utilisée

La méthodologie repose sur une architecture en deux branches principales après une reconstruction grossière initiale. Premièrement, un *Coarse SR Network* reconstruit une image HR grossière à partir de l’entrée LR. Deuxièmement, cette image grossière est envoyée en parallèle à un *Fine SR Encoder* et à un *Prior Estimation Network*. Le réseau de prior utilise une architecture HourGlass (HG) empilée pour estimer conjointement les heatmaps de landmarks et les cartes de parsing, représentant la forme géométrique du visage. Les features extraites par l’encodeur et les priors géométriques sont ensuite concaténés et décodés par un *Fine SR Decoder* pour produire l’image finale raffinée. Pour la version FSRGAN, une perte adversariale [13] et une perte perceptuelle (VGG) [14] sont ajoutées au modèle de base. L’entraînement end-to-end permet d’optimiser simultanément la qualité photométrique (PSNR) et la précision géométrique (landmarks/parsing).

Dataset utilisé

Les expérimentations sont menées sur les datasets Helen et CelebA [8]. Pour Helen [23], les 2 330 images sont utilisées (les 50 dernières pour le test), avec des images redimensionnées à 128×128 pour l’HR et 16×16 pour le LR (facteur $\times 8$). Ce dataset fournit des annotations riches : 194 landmarks et 11 cartes de parsing par image. Pour CelebA, 18 000 images servent à l’entraînement et 100 au test, avec des images de 128×128 . Les landmarks (5 points pour CelebA, étendus à 68 via un modèle externe) et les cartes de parsing sont utilisés comme supervision pour le *Prior Estimation Network*. Les images subissent une augmentation de données par rotation (90° , 180° , 270°) et flip horizontal.

Architecture proposée

L’architecture FSRNet se décompose en quatre parties : (1) le *Coarse SR Network* constitué de deux convolutions 3×3 entourant trois blocs résiduels [19], produisant une reconstruction grossière ; (2) le *Fine SR Encoder* utilisant une convolution 3×3 avec stride

2 suivie de blocs résiduels pour extraire les features à la bonne échelle (64×64); (3) le *Prior Estimation Network* basé sur deux blocs HourGlass empilés avec connexions skip, produisant les heatmaps de landmarks et les cartes de parsing via des convolutions 1×1 séparées; et (4) le *Fine SR Decoder* qui concatène les features et les priors, réduit les canaux par convolution, suréchantillonne par déconvolution 4×4 , puis applique trois blocs résiduels et une convolution finale 3×3 pour générer l'image 128×128 . La version FSRGAN ajoute un discriminateur Patch-GAN avec cinq couches de convolution et LeakyReLU.




FIG. 2.7 : Architecture de la méthode FSRNet. Source : extrait de [4].

Résultats obtenus

Sur le dataset Helen [23], FSRNet atteint 25,87 dB en PSNR et 0,7602 en SSIM, surpassant significativement les méthodes génériques (VDSR [16] : 24,61 dB, SRResNet [44] : 25,30 dB) et les méthodes faciales (URDGN [45] : 24,22 dB, GLN [46] : 24,11 dB). Sur CelebA [8], les performances sont encore meilleures avec 26,31 dB en PSNR. L'étude d'ablation démontre l'impact majeur des priors : l'utilisation des deux priors (landmarks + parsing) apporte un gain de 1,05 dB par rapport à la baseline sans prior. Les priors de parsing s'avèrent plus informatifs que les landmarks seuls (gain de 1,0 dB contre 0,4 dB). L'évaluation par alignement facial (NRMSE) montre que FSRNet permet une estimation de landmarks plus précise que les méthodes de l'état de l'art testées directement sur le LR. De même, l'évaluation par parsing facial montre que FSRNet restaure des composants faciaux complets là où SRResNet génère des formes erronées ou perd des éléments (comme la bouche). FSRGAN offre une qualité visuelle supérieure avec des textures plus réalistes au prix d'une légère baisse des métriques PSNR/SSIM.

Points forts et limites

Les points forts de FSRNet incluent son architecture end-to-end élégante qui évite les pipelines multi-étapes complexes, et l'utilisation efficace de deux types de priors géo-

métriques complémentaires. L’introduction des tâches d’alignement et de parsing comme métriques d’évaluation nouvelles pour la super-résolution faciale est particulièrement novatrice, résolvant l’incohérence entre métriques classiques (PSNR) et perception visuelle. Cependant, la méthode dépend fortement de la qualité de l’estimation des priors : si le *Coarse SR Network* échoue à produire une reconstruction suffisamment bonne, l’estimation des landmarks et du parsing devient imprécise, ce qui affecte la suite. De plus, l’architecture est conçue pour des visages relativement frontaux ; la robustesse à des poses extrêmes n’est pas explicitement testée. En conclusion, FSRNet démontre de manière convaincue que l’intégration de priors géométriques dans un cadre end-to-end permet d’obtenir des reconstructions à la fois photométriquement fidèles et géométriquement précises, ouvrant la voie à des évaluations plus complètes de la qualité des visages reconstruits.

2.1.6 SANet (Self-similarity Attention Network)

La méthode SANet proposée dans [6] exploite une information souvent négligée par les méthodes CNN classiques : l’auto-similarité intrinsèque des visages.

L’article intitulé *SANet : Face super-resolution based on self-similarity prior and attention integration*, publié en 2025 dans la revue *Pattern Recognition*, propose un réseau itératif à double branche qui intègre l’exploration de l’auto-similarité des features faciales avec un mécanisme d’attention hybride. Les auteurs, Ling Li et collaborateurs, observent que les visages présentent des structures physiques globales importantes (symétrie bilatérale approximative) et des motifs texturaux récurrents à différentes échelles (par exemple, la texture d’une dent se répète dans la bouche) que les convolutions standard ne parviennent pas à modéliser efficacement en raison de leur récepteur local limité.

Problématique traitée

Les méthodes de super-résolution faciale basées sur CNN [15] excellent à apprendre des correspondances locales mais échouent à exploiter efficacement trois caractéristiques fondamentales des visages : (1) les structures physiques globales nécessitant une modélisation de dépendances longue distance ; (2) la restauration difficile des composants informatifs clés (yeux, dents) qui demande une attention adaptative ; et (3) l’auto-similarité des motifs texturaux à l’intérieur d’une échelle et entre échelles, fournissant des exemples internes précieux pour la reconstruction. Les méthodes par attention ou par Transformers capturent certaines de ces relations mais au prix d’une complexité computationnelle élevée ou d’une perte d’intégrité structurelle. La problématique consiste à concevoir un réseau capable d’exploiter efficacement l’auto-similarité non-locale des visages tout en guidant l’attention vers les régions les plus informatives, avec une complexité maîtrisée.

Méthodologie utilisée

La méthodologie repose sur trois modules complémentaires. Le *Hybrid Attention Integration Module (HAIM)* utilise une structure en sablier (HourGlass) pour créer des cartes d’attention spatiale et canal, qui interagissent en parallèle pour mettre en avant les features des composants faciaux critiques. Le *Self-similarity Information Mining Module (SIMM)* constitue le cœur innovant : il explore trois types d’auto-similarité — intra-échelle non-locale (INSE), inter-échelles non-locale (CNSE) et échelle arbitraire (ASSE) — via une stratégie de voisinage symétrique (SNNS) exploitant la symétrie bilatérale des visages, et un mécanisme d’attention sparse non-locale agrégée (NASA) pour mesurer les corrélations feature-wise de manière efficace. Le *CycleMLP-based Reconstruction Unit (CRU)* remplace les suréchantillonneurs convolutionnels classiques par des couches fully-connected cycliques (CFCL) qui échantillonnent périodiquement les features avec une complexité linéaire, préservant une réceptive field globale flexible. L’entraînement combine une perte L1 et une perte Charbonnier.

Dataset utilisé

Les expérimentations sont conduites sur trois benchmarks : CelebA [8] (environ 202 000 paires après recadrage), Helen [23] (2 300 paires) et FFHQ [27] (70 000 paires). Les images haute résolution sont redimensionnées à 128×128 , et les images basse résolution sont obtenues par sous-échantillonnage bicubique pour les facteurs $4\times$ et $8\times$. L’augmentation de données inclut la rotation, le flip, le rescaling et l’expansion de dataset. L’évaluation utilise les métriques PSNR, SSIM (sur canal Y de YCbCr), LPIPS et MPS (Mean Perceptual Score, combinant SSIM et LPIPS). La complexité est mesurée en paramètres, GFLOPs et temps d’inférence.

Architecture proposée

L’architecture SANet est un réseau itératif à double branche. La branche supérieure utilise des HAIMs cascades pour extraire les features discriminatives contenant les propriétés structurelles et texturales clés. La branche inférieure utilise des SIMMs pour explorer les corrélations d’auto-similarité et construire des features enrichies. Les features des deux branches sont agrégées et passées au CRU pour la reconstruction finale. Concrètement, après une convolution initiale, les features traversent 12 paires HAIM-SIMM itératives. Chaque SIMM intègre les trois unités INSE, CNSE et ASSE, dont les sorties sont fusionnées par une unité d’agrégation (SIAU) avec projection résiduelle inter-features et back-projection. Le CRU final utilise trois CFCL parallèles avec des pas de 1×1 , 1×5 et 5×1 , suivis d’une projection étendue de canaux (ECP) via des ResMLPs, et enfin un

suréchantillonnage bicubique progressif par $\times 2$.




FIG. 2.8 : Architecture de la méthode SANet. Source : extrait de [6].

Résultats obtenus

Sur CelebA ($\times 8$), SANet atteint 27,99 dB en PSNR, 0,810 en SSIM, 0,078 en LPIPS [47] et 0,866 en MPS, surpassant CSNIN [48] (27,75 dB), SPARNet [49] (27,42 dB), SISN [50] (27,31 dB), NLSN [51] (27,45 dB), AD-GNN [52] (27,40 dB), CTCNet [53] (27,65 dB), SCTANet [54] (27,62 dB) et SFMNet [55] (27,56 dB). Sur Helen [23] ($\times 8$), SANet atteint 27,97 dB en PSNR et 0,837 en SSIM, nettement supérieur aux méthodes comparées. L'étude d'ablation montre que chaque unité du SIMM contribue : la combinaison INSE+CNSE+ASSE donne les meilleurs résultats (27,99 dB PSNR sur CelebA $\times 8$ contre 27,68 dB pour la baseline sans SIMM). L'insertion du SIMM dans d'autres architectures (EDSR [56], RCAN [30], SPARNet [49], SwinIR [57]) améliore systématiquement leurs performances, démontrant la flexibilité du module. L'étude du nombre de paires HAIM-SIMM montre que 12 paires offrent le meilleur compromis performance/coût. Les visualisations de similarité confirment que les features capturées présentent une distribution symétrique conforme à l'anatomie faciale.

Points forts et limites

Les points forts de SANet résident dans l'exploitation innovante de l'auto-similarité faciale à trois niveaux (intra, inter et échelle arbitraire), ce qui permet de réduire la dépendance aux données externes et d'améliorer la restauration des détails fins. Le mécanisme SNNS exploitant la symétrie faciale est particulièrement ingénieux pour réduire l'espace de recherche. Le CRU offre une alternative efficace aux upsamplers classiques avec une complexité maîtrisée (8,6M de paramètres, 11 GFLOPs). Cependant, l'architecture itérative à double branche avec 12 paires de modules reste relativement complexe. De plus, la méthode dépend de l'hypothèse de symétrie faciale qui peut être violée dans des poses non frontales ou avec des expressions asymétriques. En conclusion, SANet démontre que l'intégration de l'auto-similarité comme prior intrinsèque, combinée à une attention hy-

bride et à une reconstruction efficace, permet d’atteindre des performances de pointe avec une complexité raisonnable.

2.1.7 SLNet (Self-attention Learning Network)

La méthode SLNet proposée dans [7] adopte une approche progressive en trois étapes pour explorer complémentirement les espaces de basse et haute résolution.

L’article intitulé *Self-attention learning network for face super-resolution*, publié en 2023 dans la revue *Neural Networks*, propose un réseau d’apprentissage par auto-attention (SLNet) organisé en trois étapes successives. Les auteurs, Kangli Zeng et collaborateurs, constatent que les méthodes existantes exploitant des priors faciaux externes introduisent souvent des informations non pertinentes ou des erreurs de prédiction qui affaiblissent la reconstruction. Au lieu de s’appuyer sur des annotations de landmarks ou des cartes de parsing, SLNet utilise une architecture à trois étages qui apprend progressivement à compenser l’information manquante par auto-attention, en affinant les features de l’espace basse résolution vers l’espace haute résolution.

Problématique traitée

Les réseaux de super-résolution faciale profonds souffrent de la propagation de features redondantes et d’erreurs cumulatives lors de la reconstruction directe d’une image HR à partir du LR. Les méthodes multi-étages existantes utilisent souvent les features apprises directement pour la reconstruction sans mécanisme efficace de compensation d’information entre les étapes. De plus, l’utilisation de priors externes (landmarks, identité, parsing) bien que bénéfique, nécessite des réseaux annexes lourds et des annotations coûteuses, tout en risquant d’introduire des informations erronées si les priors sont mal estimés. La problématique centrale consiste à concevoir un réseau auto-suffisant qui progresse de manière itérative de la basse résolution vers la haute résolution, en utilisant l’auto-attention pour supprimer les features redondantes et compenser l’information manquante, sans dépendre de priors faciaux externes.

Méthodologie utilisée

La méthodologie s’articule autour de trois étapes interconnectées. La première étape, *Low-Level Face Super-Resolution (LFSR)*, utilise des blocs d’apprentissage hiérarchique basés sur des RDB (Residual Dense Blocks) pour extraire les features peu profondes de l’espace LR et générer une reconstruction intermédiaire. La deuxième étape, le *Self-Attention Module (SAM)* [7], constitue le pont entre les deux espaces : il prend

les features de LFSR et l'image d'entrée LR pour générer des cartes d'attention qui suppriment les features peu informatives et propagent uniquement les features utiles vers l'étape suivante. Une supervision intermédiaire explicite est appliquée sur la reconstruction intermédiaire. La troisième étape, *High-Level Face Super-Resolution (HFSR)*, utilise un encodeur-décodeur avec des blocs d'attention par cross-convolution (CAB) et des connexions skip pour apprendre les informations contextuelles multi-échelles dans l'espace HR et affiner la reconstruction finale. La fonction de perte combine trois termes : une perte de reconstruction (L1/L2) entre la sortie finale et le ground-truth, une perte d'auto-attention (supervision du résultat intermédiaire) et une perte asymptotique qui contraint la cohérence entre le résultat intermédiaire et le résultat final.

Architecture proposée

L'architecture SLNet se décompose en trois sous-réseaux. Le LFSR utilise trois chemins parallèles de RDBs (Residual Dense Blocks groups), chacun contenant 3 RDBs avec connexions globales skip, produisant des features hiérarchiques de bas niveau. Le SAM génère un résidu par convolution 1×1 et suréchantillonnage, ajouté à l'entrée LR pour créer une image intermédiaire I_{mid} supervisée. Des masques d'attention pixel-wise sont alors produits par sigmoid à partir de I_{mid} , recalibrant les features locales pour créer des features guidées par l'attention H_{mid} . Le HFSR est un encodeur-décodeur symétrique : l'encodeur utilise trois convolutions (7×7 , puis deux 3×3) pour extraire les features multi-échelles ; le décodeur utilise des déconvolutions correspondantes ; et des groupes de Cross-Convolutional Attention Blocks (CABs) [7] relient l'encodeur et le décodeur pour affiner les features. La sortie finale est obtenue par une convolution finale.




FIG. 2.9 : Architecture de la méthode SLNet. Source : extrait de [7].

Résultats obtenus

Sur FFHQ [27] ($\times 8$), SLNet atteint 28,43 dB en PSNR, 0,7997 en SSIM, 0,8639 en FSIM et 0,4341 en VIF, surpassant RDN [59] (27,60 dB), SAN [60] (27,75 dB), RCAN [30] (28,20 dB), SRFBN [61] (28,07 dB), MTC [62] (27,60 dB), SPARNet [49] (28,26 dB) et SISN [50] (28,40 dB). Sur CelebA [8] ($\times 8$), SLNet atteint 26,84 dB en PSNR et 0,7635 en

SSIM, établissant un nouvel état de l’art. L’étude d’ablation démontre l’importance du SAM : sans ce module, le PSNR chute de 0,87 dB sur CelebA et de 0,25 dB sur FFHQ. La visualisation des cartes de features montre que SAM permet de localiser précisément les contours et textures, éliminant le bruit redondant présent dans les features sans SAM. L’analyse des fonctions de perte montre que la combinaison des trois pertes (reconstruction + auto-attention + asymptotique avec poids 1, 0.5, 0.5) offre les meilleurs résultats (32,69 dB PSNR sur FFHQ $\times 4$). Sur les images réelles LDHF [58], SLNet restaure des détails plus fins, notamment dans les yeux, par rapport aux méthodes comparées.

Points forts et limites

Les points forts de SLNet incluent son architecture progressive en trois étapes qui affine progressivement la qualité, évitant la reconstruction directe brutale. Le module SAM est particulièrement efficace pour filtrer les informations redondantes et agir comme un pont informationnel entre l’espace LR et HR. L’utilisation de la perte asymptotique assure la cohérence entre les reconstructions intermédiaire et finale. Cependant, l’architecture avec trois étapes et des blocs RDB multiples rend le modèle relativement lourd (63 919 paramètres, 18,03 GFLOPs), plus coûteux que certaines méthodes comparées comme SPARNet. De plus, la supervision intermédiaire du SAM dépend de la qualité de la reconstruction de LFSR : si cette première étape échoue, l’attention guidée sera biaisée. En conclusion, SLNet démontre qu’une approche progressive avec auto-attention et compensation d’information entre espaces LR et HR permet d’obtenir des reconstructions fidèles sans recourir à des priors faciaux externes coûteux.

TAB. 2.1 : Comparaison synthétique des principales méthodes de super-résolution faciale

Méthode	Dataset	$\times 4$	$\times 8$	$\times 16$	Avantages	Limites
JDSR-GAN [5]	CelebA, Helen	29,18 / 0,855	26,45 / 0,763	–	Apprentissage conjoint restauration+SR	Architecture lourde (36,7M)
EFBPGAN [1]	FFHQ, CelebA-HQ	–	–	27,05* / –	Très haute qualité visuelle (prior génératif)	Dépend de StyleGAN, non validé sur masques réels
EIPNet [2]	CelebA, VGGFace2	–	25,08 / 0,7429	–	Architecture légère (guidage par contours)	Ne traite pas les masques
FCSR-GAN [3]	CelebA, Helen	24,75 / 0,761	23,77 / 0,710	–	Combine complétion et SR	Performances limitées sur masques complexes
FSRNet [4]	Helen, CelebA	–	25,87 / 0,760	–	Priors géométriques end-to-end	Dépendance aux cartes de prior
SANet [6]	CelebA, Helen, FFHQ	32,36 / 0,924	27,99 / 0,810	–	Auto-similarité + attention	Architecture complexe
SLNet [7]	FFHQ, CelebA	31,09 / 0,8809	28,43 / 0,7997	–	Auto-attention progressive	Capacité limitée pour fortes occlusions

* EFBPGAN : PSNR mesuré sur 100 images CelebA-HQ, facteur $\times 16$. Le papier original ne rapporte pas de valeur SSIM.

Analyse comparative des méthodes de l'état de l'art Le tableau 2.1 permet de comparer quantitativement les approches. JDSR-GAN atteint la meilleure fidélité objective (29,18 dB / 0,855 en $\times 4$) grâce à son apprentissage conjoint, mais son architecture est très lourde (36,7 M paramètres). Les méthodes sans occlusion (EIPNet, FSRNet, SANet, SLNet) affichent des scores compétitifs (25–32 dB) ; SANet se distingue en $\times 4$ (32,36 dB / 0,924) grâce à l'auto-similarité, mais aucune ne traite les masques. FCSR-GAN, dédié aux occlusions, a des performances modestes (24,75 dB / 0,761 en $\times 4$) et une forte dégradation en $\times 8$. EFBPGAN, orienté très grande échelle ($\times 16$), privilégie la qualité perceptuelle mais n'est pas validé sur masques réels.

2.2 Positionnement et inspirations de notre travail

Notre architecture MEFSR-GAN s’appuie sur des contributions ciblées issues des travaux présentés, synthétisées dans le tableau 2.2.

TAB. 2.2 : Sources d’inspiration ayant guidé la conception de MEFSR-GAN

Article source	Composant repris	Intégration dans MEFSR-GAN
JDSR-GAN [5]	Module de débruitage	Module 1 : suppression du masque (4 <i>ResBlocks</i>)
EFBPGAN [1]	Fusion guidée par contours	Module 2 : mécanisme <i>EdgeFusionAttention</i>
SANet [6]	Attention spatiale et canal	Module 2 : attention CBAM
FSRNet [4]	Perte perceptuelle VGG	$\mathcal{L}_{\text{percep}}$
EIPNet [2]	Perte d’identité par embedding (InceptionV1 sur VGGFace2)	$\mathcal{L}_{\text{identity}}$ (implémentée avec FaceNet)
EIPNet [2]	Contours par Canny	<code>extract_edges_canny()</code>
FCSR-GAN [3]	Apprentissage multi-tâche	Optimisation conjointe démasquage + SR
ESRGAN [9]	Blocs RRDB + discriminateur	Module 3 (v2 et v3)

2.3 Limites des approches existantes

L’analyse des travaux présentés révèle plusieurs limitations communes qui motivent notre approche. Une première limite concerne la **dépendance aux priors faciaux complets** : des méthodes telles que FSRNet [4], SANet [6] et EIPNet [2] nécessitent des landmarks ou une segmentation faciale complète, ce qui les rend inutilisables dès lors que le bas du visage est occulté par un masque. À cela s’ajoute l’**absence de traitement spécifique des masques faciaux** : à l’exception de JDSR-GAN [5], aucune méthode n’a été conçue pour gérer les masques médicaux (chirurgicaux, N95, KN95), dont la forme et la couverture sont particulièrement spécifiques.

Par ailleurs, la **complexité élevée** de certaines architectures constitue un frein important à leur déploiement pratique. JDSR-GAN [5], avec ses 36,7M paramètres, et EFBPGAN [1], avec environ 20M, sont coûteux en mémoire et en temps d’inférence, ce qui limite leur intégration dans des systèmes embarqués ou à ressources contraintes. On relève également l’**absence de guidage par contours dans le contexte masqué** : bien qu’EFBPGAN [1] exploite les informations de contours, il le fait exclusivement pour des visages non occultés. L’analyse des travaux étudiés montre qu’aucune méthode ne combine explicitement le guidage par contours et la suppression des masques faciaux au sein d’une même architecture. En outre, les approches multi-tâches restent confrontées à la difficulté du réglage des fonctions de perte, dont les coefficients doivent être soigneusement ajustés

pour garantir un apprentissage efficace. Ces paramètres étant fortement dépendants du dataset utilisé, leur transfert vers d’autres contextes d’apprentissage demeure complexe, ce qui peut affecter la reproductibilité et la capacité de généralisation des modèles.

Conclusion

Ce tour d’horizon des méthodes de super-résolution faciale montre que les approches basées sur des priors géométriques (landmarks, parsing) sont très performantes sur les visages non occultés, mais deviennent inutilisables en présence de masques. Les techniques exploitant les contours améliorent la netteté mais ignorent l’occlusion. Les modèles dédiés aux visages masqués (JDSR-GAN, FCSR-GAN) sont lourds et dépendent de masques synthétiques. Aucune méthode ne combine suppression de masque, guidage par contours et préservation d’identité dans une architecture légère adaptée à une entrée 32×32 .

Ces limitations justifient la conception de MEFSR-GAN, présentée dans le chapitre suivant.

Chapitre 3

Méthodologie proposée

Introduction

Ce chapitre présente les différentes versions de l'architecture développées pour la super-résolution de visages masqués. L'objectif est d'améliorer progressivement la qualité des images reconstruites en intégrant des modules de plus en plus sophistiqués et en affinant les fonctions de perte. Pour chaque version, nous décrivons la structure du modèle, les pertes utilisées et les paramètres d'entraînement. Les résultats quantitatifs complets sont présentés au chapitre 4.

3.1 Architectures implémentées

Comme illustré sur la Figure 1.1, l'architecture de base se décompose en trois modules successifs. La Figure 3.1 présente l'enchaînement global des versions incrémentales.




FIG. 3.1 : Architecture progressive globale du modèle MEFSR-GAN : évolution de la version 1 (ResNet simple) à la version 3 (avec discriminateur GAN).

3.1.1 Description des trois modules fondamentaux

L'architecture MEFSR-GAN repose sur trois modules successifs qui constituent le squelette commun à toutes les versions du modèle. Leur complexité interne évolue d'une version à l'autre, mais leur rôle fonctionnel reste constant.

Module 1 — Suppression du masque (MaskRemovalModule). Ce module reçoit l'image faciale basse résolution masquée $I_{LR} \in \mathbb{R}^{3 \times 32 \times 32}$ et produit une carte de caractéristiques $F_1 \in \mathbb{R}^{64 \times 32 \times 32}$ dont l'information relative au masque est progressivement atténuée. Il est constitué de 4 blocs résiduels (ResBlocks) avec normalisation par batch et activation ReLU, inspirés de l'architecture de débruitage de JDSR-GAN [5]. Le masque facial est traité comme un bruit structuré : le module apprend à en supprimer l'influence tout en préservant les caractéristiques faciales visibles dans les régions non occultées.

Module 2 — Fusion guidée par contours (EdgeFusionAttention). Ce module constitue le cœur de l'originalité architecturale de MEFSR-GAN. Il fusionne les caractéristiques F_1 issues du Module 1 avec une carte de contours $E \in \mathbb{R}^{1 \times 32 \times 32}$ extraite par l'algorithme de Canny [17] ($\sigma = 1$, seuil bas = 50, seuil haut = 150), afin de guider la reconstruction vers les structures faciales pertinentes (contours des yeux, des lèvres, de la mâchoire) malgré l'occlusion.

Le traitement s'effectue en trois étapes. D'abord, une **attention canal** recalibre

F_1 en pondérant chaque canal selon son importance globale, via un global average pooling et un global max pooling suivis d'un MLP à deux couches (facteur de réduction $r = 16$) et d'une activation sigmoïde, produisant un masque $M_c \in \mathbb{R}^{C \times 1 \times 1}$:

$$F_c = M_c \otimes F_1 \quad (3.1)$$

Ensuite, une **attention spatiale** identifie les régions les plus informatives en concaténant les projections average et max sur la dimension canal, puis en appliquant une convolution 7×7 et une sigmoïde, produisant $M_s \in \mathbb{R}^{1 \times H \times W}$:

$$F_s = M_s \otimes F_c \quad (3.2)$$

Enfin, la **fusion avec les contours** concatène F_s et E le long de la dimension canal, puis une convolution 3×3 réduit les canaux avec connexion résiduelle :

$$F_{\text{out}} = \text{Conv}_{3 \times 3}([F_s \parallel E]) + F_s \quad (3.3)$$

La connexion résiduelle garantit la préservation des caractéristiques originales dans les zones fortement occultées où les contours Canny sont peu discriminants.

Module 3 — Super-résolution (SRNetworkESRGAN). Ce module reçoit F_{out} et produit l'image haute résolution finale $\hat{I}_{\text{HR}} \in \mathbb{R}^{3 \times 128 \times 128}$. Il est basé sur l'architecture ESRGAN [9] et utilise des blocs RRDB (Residual in Residual Dense Blocks) pour l'extraction de caractéristiques profondes, suivis d'un suréchantillonnage par PixelShuffle d'un facteur $\times 4$. Le nombre de blocs RRDB varie selon la version : 8 blocs résiduels simples (ResNet) pour les versions 1.x, 12 blocs RRDB pour la v2.0, 4 blocs RRDB pour les versions 2.0 Light, et 8 blocs RRDB pour les versions 3.x et 4.

3.1.2 Version 1.0.1 : ResNet simple (MSE + Perceptuelle + Identité)

La première version constitue une baseline simple. Elle se compose de trois modules : un module de suppression du masque constitué de 4 blocs résiduels (ResBlocks) qui traitent le masque comme du bruit, un module de fusion des contours qui réalise une concaténation simple des caractéristiques et des contours extraits par l'algorithme de Canny [17], et enfin un module de super-résolution formé de 8 blocs résiduels (ResNet [19]) avec un upsampling par PixelShuffle d'un facteur $\times 4$.

Les fonctions de perte utilisées sont la perte pixel MSE avec un coefficient $\lambda = 1$, la perte perceptuelle VGG16 [18] (caractéristiques jusqu'à la couche *relu4_3*) avec $\lambda = 0,1$,

et la perte d'identité FaceNet [20] (distance cosinus) avec $\lambda = 0,01$. L'entraînement a été mené sur 100 époques avec une taille de batch de 16 et un taux d'apprentissage de 10^{-4} .

3.1.3 Version 1.0.2 : Ajout de la perte SSIM

Cette version reprend l'architecture de la v1.0.1 et ajoute une perte SSIM [21] avec un coefficient $\lambda = 0,1$. L'objectif est d'améliorer la similarité structurelle des images générées.

3.1.4 Version 1.0.3 : MAE, data augmentation et régularisation

Dans cette version, nous introduisons plusieurs améliorations. La perte pixel combine désormais MAE et MSE selon un ratio $\text{MAE} \times 0,8 + \text{MSE} \times 0,2$, ce qui favorise la préservation des bords et la netteté. Une augmentation de données par flip horizontal aléatoire est appliquée aux images d'entraînement. Enfin, une régularisation par *weight decay* de 10^{-5} est introduite dans l'optimiseur Adam. Les autres pertes (perceptuelle, identité, SSIM) sont conservées avec les mêmes poids. Cette version constitue notre meilleur modèle de référence en termes de métriques pixel-wise pures, et sert de baseline reconstructive pour l'évaluation comparative. Elle ne constitue pas la version finale de MEFSR-GAN, qui intègre par définition un discriminateur adversarial (voir version 3.1).

3.1.5 Version 2.0 (12 RRDB) : Attention et ESRGAN complet

Nous explorons ensuite une architecture plus complexe. Le module de fusion des contours est remplacé par une attention spatiale et canal nommée EdgeFusionAttention. Le module de super-résolution utilise ESRGAN [9] avec 12 blocs RRDB (Residual-in-Residual Dense Blocks). Les hyperparamètres sont ceux de la v1.0.3, mais avec un poids d'identité plus élevé ($\lambda_{\text{ID}} = 0,5$) et un poids SSIM également augmenté ($\lambda_{\text{SSIM}} = 0,5$). FaceNet est activé toutes les 10 époques pour limiter le coût de calcul.

3.1.6 Version 2.0 Light (4 RRDB) : Adaptation à la basse résolution

Pour pallier les problèmes de la version précédente, nous réduisons le nombre de blocs RRDB de 12 à 4, tout en conservant l'attention et les pertes de la v1.0.3 ($\lambda_{\text{ID}} = 0,01$, $\lambda_{\text{SSIM}} = 0,1$, FaceNet à chaque époque). Cette architecture allégée est mieux adaptée aux entrées 32×32 . La stagnation observée entre 100 et 200 époques suggère que la fonction

de perte MSE seule atteint ses limites, motivant l'introduction d'une perte pixel combinée MAE+MSE dans les versions suivantes.

3.1.7 Version 2.0 Light New (4 RRDB + MAE $\times$ 0,8 + MSE $\times$ 0,2) : Optimisation de la perte pixel

Cette version reprend l'architecture de la v2.0 Light et introduit deux améliorations clés. D'une part, la perte pixel combinée remplace le MSE seul par une combinaison MAE $\times$ 0,8 + MSE $\times$ 0,2, inspirée des gains observés en v1.0.3. Le MAE dominant favorise la préservation des bords et réduit le flou caractéristique du MSE. D'autre part, l'augmentation des données est étendue : flip horizontal et vertical, rotation à 90°, et variation aléatoire de luminosité, appliquées de manière cohérente aux paires (entrée, cible). Enfin, la perte d'identité est optimisée : FaceNet est calculé sur un batch sur quatre avec $\lambda_{ID} = 0,05$, ce qui réduit le coût de calcul de 37% sans impact significatif sur la qualité.

Note importante sur la comparabilité du SSIM : le SSIM de 0,8588 rapporté pour la v2.0 Light New a été calculé avec une implémentation sans fenêtrage gaussien (SSIM global sur l'image entière), tandis que toutes les autres versions utilisent l'implémentation `pytorch_msssim` avec fenêtrage gaussien 11 $\times$ 11, conforme à la définition originale [21]. Ces deux implémentations produisent des valeurs systématiquement différentes et **ne sont pas directement comparables**. Par conséquent, le SSIM de v2.0 Light New est exclu de toute comparaison quantitative avec les autres versions dans le tableau 4.4 et dans l'analyse des résultats.

3.1.8 Version 3.0 : Entraînement adversarial — MEFSR-GAN

La version 3.0 constitue l'aboutissement du projet. Elle adopte une stratégie d'entraînement en deux phases : un pré-entraînement complet du générateur suivi de l'introduction d'un discriminateur adversarial, conformément aux recommandations de la littérature [9, 5].

Architecture du générateur

Le générateur reprend exactement l'architecture à trois modules décrite dans la section 3.1.1 (pages 38) : MaskRemovalModule, EdgeFusionAttention et SRNetworkESRGAN. Les détails architecturaux (équations de l'attention, fusion avec les contours Canny, nombre de canaux) sont donnés dans cette section. Pour la version 3.0, le module SRNetworkESRGAN utilise **8 blocs RRDB** [9] (contre 4 dans les versions 2.0 Light). Le générateur totalise **6 618 791 paramètres entraînables**.

Architecture du discriminateur

Un discriminateur de type PatchGAN à 5 couches convolutives est ajouté en phase 2. Contrairement à un discriminateur global, le PatchGAN évalue la vraisemblance de *patches* locaux de taille 70×70 pixels, ce qui favorise la génération de textures fines et de contours nets [10]. Le tableau 3.1 détaille l’architecture de ce discriminateur.

TAB. 3.1 : Architecture du discriminateur PatchGAN (v3.0)

Couche	Filtres	Stride	Normalisation
Conv1	64	2	Aucune
Conv2	128	2	BatchNorm
Conv3	256	2	BatchNorm
Conv4	512	2	BatchNorm
Conv5	1	1	Aucune
Total paramètres			2 765 633

Fonctions de perte

La perte totale du générateur intègre cinq termes complémentaires (hors terme adversarial, détaillé en section 3.2.5) :

$$\mathcal{L}_{\text{total}} = \lambda_{\text{pixel}} \mathcal{L}_{\text{pixel}} + \lambda_{\text{percep}} \mathcal{L}_{\text{percep}} + \lambda_{\text{SSIM}} \mathcal{L}_{\text{SSIM}} + \lambda_{\text{ID}} \mathcal{L}_{\text{ID}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} \quad (3.4)$$

La perte adversariale $\mathcal{L}_{\text{adv}}$ est basée sur la formulation LSGAN (Least-Squares GAN) [11], plus stable que la perte BCE standard et moins sujette au *mode collapse* :

$$\mathcal{L}_{\text{adv}}^D = \mathbb{E}[(D(\mathbf{y}) - 1)^2] + \mathbb{E}[D(G(\mathbf{x}))^2] \quad \mathcal{L}_{\text{adv}}^G = \mathbb{E}[(D(G(\mathbf{x})) - 1)^2] \quad (3.5)$$

Stratégie d’entraînement en deux phases

Phase 1 — Pré-entraînement du générateur (époques 1–50). Le générateur est entraîné seul sans discriminateur. La valeur $\lambda_{\text{adv}} = 0$ pendant cette phase garantit une convergence stable avant l’introduction de la pression adversariale. Le taux d’apprentissage initial est fixé à 10^{-4} , réduit automatiquement par un scheduler `ReduceLROnPlateau`. À l’époque 50, la perte de validation atteint un plateau à $\mathcal{L}_{\text{val}} = 0,4749$, signalant la convergence du générateur et justifiant le passage en phase 2.

Phase 2 — Entraînement adversarial (époques 51–80). Le discriminateur PatchGAN est introduit avec un taux d’apprentissage réduit de moitié (5×10^{-5}) pour

éviter de déstabiliser le générateur pré-entraîné. La valeur initiale $\lambda_{\text{adv}} = 0,1$ est volontairement conservatrice pour laisser les pertes perceptuelles et d'identité rester dominantes.

Correction du drift d'identité (époque 65). Une observation visuelle à l'époque 65 a révélé un phénomène de **dérive d'identité** (*identity drift*) : le générateur produisait des détails faciaux plausibles (dents, barbe) mais différents de ceux de l'image cible. Ce comportement, documenté dans la littérature GAN [9], résulte d'un déséquilibre entre la perte adversariale et la perte d'identité. Pour y remédier, λ_{ID} a été augmenté de 0,2 à 0,4 et λ_{adv} réduit de 0,1 à 0,05, tout en calculant la perte d'identité deux fois plus souvent (`IDENTITY_EVERY = 2`). La reprise de l'entraînement s'est effectuée depuis le checkpoint de l'époque 65 sans perte des poids acquis, grâce au mécanisme de sauvegarde `latest_gan_checkpoint.pth` incluant les états du générateur, du discriminateur et des deux optimiseurs.

Rééquilibrage final (épisodes 76–80). À l'époque 75, la perte du discriminateur $\mathcal{L}_D$ est descendue à 0,35, indiquant que le discriminateur devenait trop fort par rapport au générateur. Le coefficient adversarial a été légèrement relevé à $\lambda_{\text{adv}} = 0,07$ pour rétablir l'équilibre G/D dans la zone cible [0,20; 0,48].

3.1.9 Version 3.1 : Entraînement adversarial conjoint (end-to-end)

La version 3.1 constitue une évolution directe de la v3.0, proposée pour explorer une stratégie d'entraînement alternative à la double-phase. Plutôt que de pré-entraîner le générateur seul avant d'introduire le discriminateur, le générateur et le discriminateur sont entraînés conjointement dès la première époque.

Architecture

L'architecture du générateur est identique à celle de la v3.0 (trois modules successifs : MaskRemovalModule, EdgeFusionAttention et SRNetworkESRGAN à 8 blocs RRDB). Le discriminateur PatchGAN à 5 couches est conservé avec la formulation LS-GAN. La différence fondamentale réside dans la stratégie d'entraînement et dans le calibrage des hyperparamètres.

Problème du discriminateur trop fort et correction

Lors d'un premier essai ($\text{LR}_D = 10^{-4}$), le discriminateur apprenait à distinguer les images réelles des images générées dès les premières époques, réduisant sa perte $\mathcal{L}_D$

à moins de 0,001 dès l'époque 3. Ce phénomène, appelé **effondrement du discriminateur** (*discriminator collapse*), annule le signal adversarial transmis au générateur. Deux corrections ont été appliquées. D'une part, le taux d'apprentissage du discriminateur a été abaissé de 10^{-4} à 10^{-5} , soit dix fois moins que celui du générateur ($LR_G = 10^{-4}$). Cela ralentit l'apprentissage du discriminateur et lui laisse le temps de rester en compétition équilibrée avec le générateur. D'autre part, une mise à jour alternée a été mise en place : le discriminateur n'est mis à jour qu'un batch sur deux ($D_UPDATE_EVERY = 2$). Pour chaque itération i , la mise à jour du discriminateur n'est effectuée que si $i \bmod 2 = 0$, tandis que le générateur est mis à jour à chaque itération. Après ces corrections, la perte du discriminateur s'est stabilisée dans la plage saine $[0,16; 0,26]$ pendant l'intégralité des 80 époques, confirmant l'équilibre G/D.

Stratégie de protection du PSNR

Le coefficient adversarial est volontairement fixé à une valeur très faible ($\lambda_{adv} = 0,01$) pour deux raisons. D'abord, sans pré-entraînement, le générateur doit apprendre simultanément la reconstruction de base et le réalisme adversarial ; un poids adversarial trop élevé perturberait l'apprentissage des pertes fondamentales (pixel, perceptuelle). Ensuite, un poids adversarial faible préserve le PSNR, qui tend à diminuer lorsque le discriminateur optimise le réalisme perceptuel au détriment de la fidélité pixel. Le coefficient pixel est en contrepartie augmenté à $\lambda_{pixel} = 0,8$ (contre 0,5 en v3.0) pour renforcer la fidélité pixel en l'absence de pré-entraînement.

Progression de l'entraînement

L'entraînement s'est déroulé sur 80 époques, réparties sur quatre sessions Kaggle (GPU T4, 12 heures par session), avec sauvegarde automatique des checkpoints et reprise inter-sessions. Le Tableau 3.2 récapitule la progression des métriques de validation.

TAB. 3.2 : Progression du PSNR (validation) et de la Loss_D au fil des époques — v3.1_GAN

Époque	PSNR val (dB)	SSIM val	Loss_G	Loss_D
10	22,52	0,750	0,576	0,161
15	23,16	0,764	0,555	0,179
20	23,37	0,768	0,539	0,198
30	23,54	0,775	0,520	0,226
50	23,92	0,785	0,499	0,234
55	24,23	0,785	0,496	0,233
60	24,14	0,786	0,492	0,241
70	23,39	0,787	0,488	0,233
80	24,04	0,783	0,483	0,235

Trois observations méritent d’être soulignées. Premièrement, l’absence d’overfitting : le gap entre la perte d’entraînement et la perte de validation est resté stable entre +0,033 et +0,047 tout au long des 80 époques, sans divergence croissante. Deuxièmement, l’absence de mode collapse : la perte du discriminateur $\mathcal{L}_D$ est restée dans la plage saine [0,16; 0,26] pendant les 70 dernières époques, confirmant l’équilibre G/D. Troisièmement, des oscillations GAN normales sont observées : des fluctuations du PSNR de validation (par exemple 23,39 dB à l’époque 70 puis 24,04 dB à l’époque 80) sont caractéristiques des micro-ajustements continus de l’équilibre G/D. Le meilleur modèle est sauvegardé à chaque amélioration du PSNR de validation.

Artefacts en damier et leur disparition

À l’époque 10, des artefacts en damier (*checkerboard artifacts*) ont été observés dans la zone buccale des images générées. Ce phénomène, caractéristique des GAN en début d’entraînement, résulte de la pression adversariale sur la zone la plus incertaine (occultée par le masque). Ces artefacts ont disparu spontanément dès l’époque 15, le générateur ayant appris à produire des textures cohérentes plutôt que des motifs répétitifs.

3.1.10 Version 4 : Discriminateur WGAN-GP

La version 4 explore le remplacement de la formulation LSGAN par une approche WGAN-GP (Wasserstein GAN with Gradient Penalty) [12], pour sa plus grande stabilité théorique et sa résistance au mode collapse.

Fondements théoriques du WGAN-GP

Le GAN standard [13] (et sa variante LSGAN [11]) minimise une forme de divergence de Jensen-Shannon entre les distributions réelle et générée. Cette divergence peut s'annuler lorsque les supports des deux distributions ne se chevauchent pas, provoquant des gradients nuls et le mode collapse. Le WGAN substitue cette divergence par la distance de Wasserstein (ou Earth Mover's distance) :

$$W(p_r, p_g) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x \sim p_r}[f(x)] - \mathbb{E}_{x \sim p_g}[f(x)] \quad (3.6)$$

où f est une fonction 1-Lipschitz. La distance de Wasserstein fournit un gradient non nul même lorsque les distributions ne se chevauchent pas, ce qui améliore la stabilité d'entraînement. La contrainte Lipschitz est imposée via une pénalité de gradient (Gradient Penalty, GP) [12] plutôt que par le clipping de poids (WGAN original) :

$$\mathcal{L}_{GP} = \lambda_{gp} \mathbb{E}_{\hat{x} \sim p_{\hat{x}}} [(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2] \quad (3.7)$$

où $\hat{x}$ est un point interpolé entre une image réelle et une image générée, et λ_{gp} est le coefficient de pénalité (typiquement $\lambda_{gp} = 10$). La perte totale du discriminateur devient :

$$\mathcal{L}_D^{\text{WGAN-GP}} = \mathbb{E}_{\tilde{x} \sim p_g}[D(\tilde{x})] - \mathbb{E}_{x \sim p_r}[D(x)] + \mathcal{L}_{GP} \quad (3.8)$$

$$\mathcal{L}_G^{\text{WGAN-GP}} = -\mathbb{E}_{\tilde{x} \sim p_g}[D(\tilde{x})] \quad (3.9)$$

Contrairement à LSGAN, le discriminateur WGAN-GP n'est pas borné à $[0, 1]$ et joue le rôle d'un *critique* (d'où l'appellation courante « critic » plutôt que « discriminateur »).

Différences architecturales par rapport à la v3.1

Le générateur est identique à celui des versions précédentes. La différence principale est la suppression de la couche de normalisation BatchNorm dans le critique WGAN-GP, car la BatchNorm introduit des corrélations entre les exemples d'un même batch qui interfèrent avec la pénalité de gradient [12].

TAB. 3.3 : Comparaison finale v3.1_GAN et v4 WGAN-GP sur le test set

Version	PSNR (dB)	SSIM	Formulation GAN
v3.1 GAN (conjoint)	$24,49 \pm 2,38$	$0,7902 \pm 0,0623$	LSGAN [11]
v4 WGAN-GP	$24,58 \pm 2,42$	$0,7277 \pm 0,0657$	WGAN-GP [12]

La v4 WGAN-GP obtient le PSNR le plus élevé (24,58 dB), mais présente un SSIM significativement inférieur à la v3.1 (0,7277 contre 0,7902). La différence de PSNR est inférieure au seuil de perception humaine (0,5 dB). En conséquence, la version v3.1 reste retenue comme version finale.

3.2 Fonctions de perte détaillées

La fonction de perte totale de MEFSR-GAN, hors terme adversarial, est une combinaison pondérée de quatre termes complémentaires, chacun ciblant un aspect spécifique de la qualité de reconstruction. Elle s'écrit :

$$\mathcal{L}_{\text{total}} = \lambda_{\text{pixel}} \mathcal{L}_{\text{pixel}} + \lambda_{\text{percep}} \mathcal{L}_{\text{percep}} + \lambda_{\text{ID}} \mathcal{L}_{\text{ID}} + \lambda_{\text{SSIM}} \mathcal{L}_{\text{SSIM}} \quad (3.10)$$

3.2.1 Perte pixel (MAE + MSE)

La perte pixel mesure directement la fidélité entre l'image générée I_{SR} et l'image cible I_{HR} au niveau de chaque pixel. Nous utilisons une combinaison des deux normes classiques. La MSE (Mean Squared Error), définie par $\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (I_{\text{HR}}^i - I_{\text{SR}}^i)^2$, pénalise fortement les grandes erreurs, ce qui favorise la convergence mais tend à produire des images trop lissées manquant de détails haute fréquence. La MAE (Mean Absolute Error), définie par $\mathcal{L}_{\text{MAE}} = \frac{1}{N} \sum_{i=1}^N |I_{\text{HR}}^i - I_{\text{SR}}^i|$, est moins sensible aux valeurs aberrantes et préserve mieux les bords et contours faciaux, produisant des reconstructions plus nettes. La combinaison adoptée est :

$$\mathcal{L}_{\text{pixel}} = 0,8 \cdot \mathcal{L}_{\text{MAE}} + 0,2 \cdot \mathcal{L}_{\text{MSE}} \quad (3.11)$$

Le coefficient $\alpha = 0,8$ en faveur de la MAE a été déterminé expérimentalement (voir section 4.3.6, chapitre 4). Cette pondération permet de bénéficier de la stabilité de la MSE tout en favorisant la préservation des bords caractéristique de la MAE.

3.2.2 Perte perceptuelle (VGG16)

Introduite par Johnson et al. [14], la perte perceptuelle compare les images dans l'espace des caractéristiques d'un réseau pré-entraîné plutôt qu'au niveau pixel. Nous utilisons les activations de la couche *relu4_3* de VGG16 [18]. La perte est définie par :

$$\mathcal{L}_{\text{percep}} = \frac{1}{W_j H_j C_j} \sum_{x,y,c} (\phi_j(I_{\text{SR}})_{x,y,c} - \phi_j(I_{\text{HR}})_{x,y,c})^2 \quad (3.12)$$

où ϕ_j représente les activations de la couche j de VGG16, et W_j, H_j, C_j sont les dimensions spatiales et canaux de la carte de caractéristiques correspondante. Cette perte capture les similarités perceptuelles que la comparaison pixel à pixel ne peut pas mesurer (textures, structures globales, cohérence sémantique). Présente dès la première version de notre modèle (v1.0.1), la perte perceptuelle s'avère essentielle pour la qualité visuelle ; des expériences de retrait (non détaillées ici) montrent qu'elle contribue à un gain d'environ 0,51 dB en PSNR par rapport à une configuration sans elle. Nous utilisons $\lambda_{\text{percep}} = 0,1$.

3.2.3 Perte d'identité (FaceNet)

La préservation de l'identité faciale est un objectif critique dans notre tâche, car la reconstruction doit permettre une reconnaissance faciale ultérieure même après suppression du masque. Nous utilisons un réseau FaceNet [20] pré-entraîné pour extraire des embeddings d'identité. La perte est définie par :

$$\mathcal{L}_{\text{ID}} = 1 - \frac{\text{Embed}(I_{\text{SR}}) \cdot \text{Embed}(I_{\text{HR}})}{\|\text{Embed}(I_{\text{SR}})\| \cdot \|\text{Embed}(I_{\text{HR}})\|} \quad (3.13)$$

où $\text{Embed}(\cdot)$ désigne l'embedding FaceNet normalisé en L2, et la fraction représente la similarité cosinus entre les embeddings de l'image reconstruite et de l'image cible. Une valeur proche de 0 indique une identité parfaitement préservée.

3.2.4 Perte SSIM

La perte SSIM [21] (Structural Similarity Index Measure) évalue la similarité structurelle entre l'image reconstruite et l'image cible en comparant trois composantes : la luminance, le contraste et la structure locale. La formule du SSIM est :

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (3.14)$$

où μ_x, μ_y sont les moyennes locales, σ_x^2, σ_y^2 les variances locales, σ_{xy} la covariance locale, et C_1, C_2 des constantes de stabilité numérique. La perte associée est :

$$\mathcal{L}_{\text{SSIM}} = 1 - \text{SSIM}(I_{\text{SR}}, I_{\text{HR}}) \quad (3.15)$$

3.2.5 Perte adversariale (versions GAN)

Les versions GAN (v3.0, v3.1 et v4) introduisent un terme adversarial. La formulation LSGAN adoptée pour v3.0 et v3.1 est :

$$\mathcal{L}_{\text{adv}}^G = \mathbb{E}[(D(G(I_{\text{LR}})) - 1)^2] \quad (3.16)$$

Le coefficient λ_{adv} varie selon les versions. Pour la v3.0, $\lambda_{\text{adv}} \in \{0,10; 0,05; 0,07\}$ (ajusté progressivement selon l'équilibre entre générateur et discriminateur). Pour la v3.1, $\lambda_{\text{adv}} = 0,01$ (volontairement très faible pour protéger le PSNR en l'absence de pré-entraînement). Pour la v4, la formulation est celle de Wasserstein avec pénalité de gradient (voir section précédente). La fonction de perte totale pour les versions adversariales devient alors :

$$\mathcal{L}_{\text{total}}^{v\text{GAN}} = \lambda_{\text{pixel}} \mathcal{L}_{\text{pixel}} + \lambda_{\text{percep}} \mathcal{L}_{\text{percep}} + \lambda_{\text{ID}} \mathcal{L}_{\text{ID}} + \lambda_{\text{SSIM}} \mathcal{L}_{\text{SSIM}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} \quad (3.17)$$

3.2.6 Récapitulatif des coefficients

Le tableau 3.4 résume les coefficients utilisés pour chaque version de MEFSR-GAN.

TAB. 3.4 : Coefficients des fonctions de perte par version

Version	λ_{pixel}	λ_{percep}	λ_{SSIM}	λ_{ID}	λ_{adv}
v1.0.1	1,0 (MSE)	0,1	—	0,01	—
v1.0.2	1,0 (MSE)	0,1	0,1	0,01	—
v1.0.3	1,0 (MAE+MSE)	0,1	0,1	0,01	—
v2.0 (12 RRDB)	1,0 (MSE)	0,1	0,5	0,5	—
v2.0 Light	1,0 (MSE)	0,1	0,1	0,01	—
v2.0 Light New	1,0 (MAE+MSE)	0,1	0,1	0,05	—
v3.0 Phase 1	0,5 (MAE+MSE)	0,4	0,4	0,2	—
v3.0 GAN ep. 51–65	0,5 (MAE+MSE)	0,4	0,4	0,2	0,10
v3.0 GAN ep. 66–75	0,5 (MAE+MSE)	0,4	0,4	0,4	0,05
v3.0 GAN ep. 76–80	0,5 (MAE+MSE)	0,4	0,4	0,4	0,07
v3.1 GAN (conjoint)	0,8 (MAE+MSE)	0,4	0,4	0,3	0,01
v4 WGAN-GP	0,8 (MAE+MSE)	0,4	0,4	0,3	(Wasserstein)

Conclusion

La méthodologie proposée a permis de construire une famille de modèles de super-résolution faciale, de la baseline simple à une architecture avancée avec attention, blocs RRDB et plusieurs stratégies adversariales. L'architecture ESRGAN allégée (4 RRDB) avec perte pixel optimisée constitue une piste prometteuse. La version 3.1, qui combine un générateur ESRGAN à 8 RRDB et un discriminateur LSGAN entraîné conjointement, établit le meilleur compromis entre fidélité pixel et préservation structurelle, avec un PSNR de 24,49 dB et un SSIM de 0,7902. L'approche WGAN-GP (version 4), bien que novatrice, ne démontre pas de supériorité sur notre tâche. Le chapitre suivant présente les résultats expérimentaux détaillés et la comparaison avec l'état de l'art.

Chapitre 4

Résultats Expérimentaux

Introduction

Ce chapitre présente les résultats expérimentaux de MEFSR-GAN : données, protocole, résultats quantitatifs et qualitatifs, étude d’ablation et comparaison avec l’état de l’art.

4.1 Données expérimentales

4.1.1 Description du dataset

Pour l’entraînement et l’évaluation de notre modèle MEFSR-GAN, nous avons utilisé le dataset **Masked CelebA-HQ Cropped**, une version augmentée de CelebA-HQ [8] spécialement conçue pour la recherche sur les visages masqués dans le contexte de la pandémie de COVID-19. Ce dataset est constitué de 24 678 paires d’images validées. Les images originales non masquées sont au nombre de 30 571, mais 5 893 d’entre elles n’ont pas pu être appariées à une version masquée valide, d’où le nombre final de paires effectives. Les images masquées (24 678) comportent des masques synthétiques de différents types : surgical, N95, KN95, cloth, gas mask et inpaint. La résolution native est de 128×128 pixels, à la fois pour les images masquées et pour les images propres. Le dataset est organisé en deux dossiers principaux : `facesDataset/` contient les images de visages propres (ground truth), tandis que `facesDataset_masked/` rassemble les visages avec masques synthétiques appliqués. Les masques ont été générés de manière réaliste à l’aide de l’outil open-source **MaskTheFace** [63], qui permet d’appliquer différents types de protections faciales (chirurgical, N95, tissu, etc.) en respectant l’angle, la position et les contours du visage. Chaque image masquée est associée à son image propre par un iden-

tifiant numérique (par exemple, 0000123.png 0000123_surgical.png), comme illustré dans la Figure 4.1.




FIG. 4.1 : Exemple de paire d'images du dataset. À gauche : image d'entrée basse résolution (32×32) avec masque. À droite : image cible haute résolution (128×128) sans masque.

4.1.2 Prétraitement des données

Le prétraitement des données constitue une étape cruciale pour adapter le dataset original (128×128) aux exigences de notre tâche de super-résolution $\times 4$ ($32 \times 32 \rightarrow 128 \times 128$). Cette étape a été réalisée via un script Python automatisé exécuté sur la plateforme Kaggle.

Création des paires valides

La première étape consiste à identifier et valider les paires d'images masquées et non-masquées. Pour chaque image masquée (par exemple 0000123_surgical.png), on extrait le préfixe numérique (0000123) puis on recherche l'image non-masquée correspondante (0000123.png). Seules les paires complètes sont conservées. Sur les 24 678 images masquées disponibles, 100 % ont été appariées avec succès à leurs versions non-masquées, donnant ainsi 24 678 paires valides.

Redimensionnement et partition des données

Les données ont ensuite été redimensionnées et divisées selon le protocole suivant. Les images d'entrée (LR) sont obtenues par un sous-échantillonnage bicubique (cv2.INTER_CUBIC) de 128×128 à 32×32 , tandis que les images cibles (HR) sont conservées à leur résolution native de 128×128 pixels. Le facteur d'upsampling est donc de $\times 4$,

standard pour la super-résolution faciale. Le choix de l'interpolation bicubique pour le sous-échantillonnage est motivé par sa capacité à mieux préserver les détails et à éviter les artéfacts d'aliasing par rapport à l'interpolation bilinéaire.

Le dataset complet a été divisé aléatoirement (avec une graine fixe `seed = 42` pour la reproductibilité) selon la distribution standard 80/10/10. Le tableau 4.1 présente la répartition des images entre les ensembles d'entraînement, de validation et de test.

TAB. 4.1 : Répartition du dataset MEFSR-GAN

Split	Nombre d'images	Pourcentage	Usage
Train	19 742	80%	Entraînement du modèle
Validation	2 467	10%	Réglage des hyperparamètres
Test	2 469	10%	Évaluation finale
Total	24 678	100%	—

4.1.3 Augmentation des données

Pour améliorer la robustesse et la généralisation du modèle MEFSR-GAN, nous avons mis en place une chaîne d'augmentation de données systématique, appliquée exclusivement à l'ensemble d'entraînement. Ces transformations sont appliquées de manière aléatoire et identique sur les paires d'images (basse résolution masquée et haute résolution cible) afin de conserver la cohérence spatiale et photométrique.

Sur le plan géométrique, chaque paire d'images peut subir un retournement gauche-droite avec une probabilité de 50%, un retournement haut-bas avec la même probabilité, ainsi qu'une rotation aléatoire par multiples de 90° (0°, 90°, 180° ou 270°), chaque angle étant équiprobable. Sur le plan photométrique, la luminosité est ajustée en multipliant les pixels par un facteur tiré uniformément dans l'intervalle $[0, 85; 1, 15]$, avec une probabilité d'application de 50%, suivi d'un écrêtage dans $[0, 1]$. Le même facteur est appliqué à l'image d'entrée et à l'image cible, ce qui préserve la relation de super-résolution.

Toutes les opérations sont implémentées nativement sous PyTorch et intégrées dans la classe `FaceSRDataset` via la méthode `_augment()`. L'ordre est fixe (transformations géométriques puis photométrique) pour garantir la reproductibilité. Aucune augmentation n'est appliquée aux ensembles de validation et de test, afin d'évaluer les performances sur des données non modifiées. Ces techniques permettent d'augmenter virtuellement la taille du jeu d'entraînement, de réduire le surapprentissage et de rendre le modèle invariant aux symétries et aux faibles variations d'éclairage.

4.2 Métriques d'évaluation

L'évaluation quantitative de MEFSR-GAN repose sur deux métriques complémentaires, couvrant la fidélité pixel-wise et la similarité structurelle.

4.2.1 PSNR (Peak Signal-to-Noise Ratio)

Le PSNR mesure le rapport entre la puissance maximale du signal et la puissance du bruit de reconstruction :

$$\text{PSNR} = 10 \log_{10} \left(\frac{MAX^2}{MSE} \right) = 20 \log_{10} \left(\frac{MAX}{\sqrt{MSE}} \right) \quad (4.1)$$

où $MAX = 255$ est la valeur maximale d'un pixel (images 8 bits) et MSE l'erreur quadratique moyenne entre l'image reconstruite et l'image de référence. Le PSNR est exprimé en décibels (dB) : des valeurs plus élevées indiquent une meilleure fidélité.

Dans notre contexte de super-résolution $\times 4$ avec suppression de masque ($32 \times 32 \rightarrow 128 \times 128$), la baseline par interpolation bicubique atteint 23,00 dB. Les méthodes de l'état de l'art pour des visages non masqués atteignent généralement 25–30 dB sur des configurations similaires. Notre objectif cible est $\text{PSNR} \geq 25$ dB.

4.2.2 SSIM (Structural Similarity Index Measure)

Le SSIM [21] évalue la similarité structurelle entre deux images en comparant la luminance, le contraste et la structure locale (voir équation 3.15, chapitre 3). La valeur est comprise entre -1 et 1 , où 1 indique une similarité parfaite. Contrairement au PSNR qui traite les pixels indépendamment, le SSIM capture les corrélations spatiales locales et est plus cohérent avec la perception humaine. Des valeurs supérieures à $0,80$ sont considérées comme excellentes pour la super-résolution faciale. Notre objectif cible est $\text{SSIM} \geq 0,80$.

4.3 Protocole expérimental

4.3.1 Environnement expérimental

L'ensemble des expériences a été réalisé sur la plateforme **Kaggle**. Le tableau 4.2 récapitule les ressources matérielles et logicielles utilisées, ainsi que les durées d'entraînement pour chaque version.

TAB. 4.2 : Ressources expérimentales et temps d'entraînement

GPU	NVIDIA Tesla P100 (16 Go VRAM) et T4 (15 Go VRAM)
Framework	PyTorch 2.2.2 + CUDA 11.8
Bibliothèques	OpenCV 4.8 (prétraitement); FaceNet-PyTorch [20] (perte d'identité); pytorch-msssim [21] (perte SSIM, fenêtrage gaussien 11×11)
Temps d'entraînement	
v1.0.3	~8h (100 époques $\times$ 5 min/époque)
v2.0 Light	~20h (100 époques $\times$ 12 min/époque)
v3.0 GAN	~40h (80 époques, dont 30 avec discriminateur)
v3.1 GAN (conjoint)	~48h (80 époques $\times$ 12 min/époque, réparties sur 4 sessions Kaggle)
v4 (WGAN-GP)	~30h (75 époques $\times$ 12 min/époque)

4.3.2 Hyperparamètres d'entraînement

Tous les modèles ont été optimisés avec l'algorithme **Adam** [22] ($\beta_1 = 0,9$, $\beta_2 = 0,999$), en utilisant un taux d'apprentissage initial de 10^{-4} . Un scheduler **ReduceLROnPlateau** a été appliqué : si la perte de validation ne diminuait pas pendant 5 époques consécutives, le taux d'apprentissage était divisé par 2 ($factor = 0,5$). Une régularisation par *weight decay* (10^{-5}) a également été utilisée pour limiter le surapprentissage. Le tableau 4.3 résume les hyperparamètres communs aux différentes versions. Les détails des stratégies d'entraînement (phases, corrections de dérive d'identité, mise à jour alternée, etc.) sont présentés dans le chapitre 3, sections dédiées.

TAB. 4.3 : Hyperparamètres d'entraînement pour les versions principales

Paramètre	v1.0.3	v2.0 Light	v3.0 GAN	v3.1 GAN	v4 (WGAN-GP)
Batch size	16	16	16	16	16
LR G	10^{-4}	10^{-4}	Ph.1 : 10^{-4}	10^{-4}	10^{-4} puis 10^{-5}
LR D	–	–	Ph.2 : 5×10^{-5}	10^{-5}	10^{-4}
Optimizer	Adam	Adam	Adam (G&D)	Adam (G&D)	Adam (G&critique)
Weight decay	10^{-5}	10^{-5}	10^{-5}	10^{-5}	10^{-5}
LR scheduler	ReduceLROnPlateau (patience=5, factor=0,5)				
Époques	100	100–150	80 (P1:50, P2:30)	80	75

4.3.3 Résultats quantitatifs

TAB. 4.4 : Comparaison expérimentale des différentes versions de MEFSR-GAN

Version	Architecture / Configuration	Ép.	PSNR (dB)	SSIM
Bicubic	Interpolation bicubique	–	23,00	0,6500
v1.0.1	ResNet (8 blocs) + MSE + Percep + ID	100	24,61	0,7841
v1.0.2	ResNet + MSE + Percep + ID + SSIM	100	24,80	0,8090
v1.0.3	ResNet + MAE×0,8+MSE×0,2 + Percep + ID + SSIM + Aug	100	25,03	0,8163
v2.0	ESRGAN (12 RRDB) + Attention + MSE + Percep + ID + SSIM + Aug	100	23,57	0,7915
v2.0 Light	ESRGAN (4 RRDB) + Attention + MSE + Percep + ID + SSIM + Aug	200	24,82	0,8128
v2.0 L. New	ESRGAN (4 RRDB) + Attention + MAE×0,8+MSE×0,2	150	24,46	0,8588*
v3.0 Phase 1	3 modules (MaskRemoval + EdgeFusion + ESRGAN 8 RRDB), MAE+MSE + Percep + SSIM + ID (sans disc.)	50	24,28	–
v3.0 GAN	Générateur v3.0 + PatchGAN LS-GAN + corr. drift (ép. 65)	80	23,45 ± 2,19	0,7711 ± 0,0675
v3.1 GAN (conjoint)	Générateur v3.0 + PatchGAN LS-GAN, conjoint ($LR_D = 10^{-5}$, $\lambda_{adv}=0,01$, $\lambda_{pixel}=0,8$)	80	24,49 ± 2,38	0,7902 ± 0,0623
v4 (WGAN-GP)	Générateur v3.0 + critique WGAN-GP, pré-entr. G (60 ép.) puis 15 ép. conjointes	75	24,58 ± 2,42	0,7277 ± 0,0657

* SSIM calculé sans fenêtrage gaussien (implémentation globale) — **non comparable** aux autres versions qui utilisent pytorch_msssim avec fenêtrage gaussien 11×11. Cette valeur est indiquée à titre indicatif uniquement ; toute comparaison directe avec les autres lignes du tableau serait incorrecte.




FIG. 4.2 : À gauche : courbes d'entraînement de la version v1.0.2 (MSE + Perceptual + Identity + SSIM). À droite : courbes d'entraînement de la version v1.0.3 Light. Les deux versions montrent une convergence stable avec une diminution progressive de la loss et une amélioration du PSNR.




FIG. 4.3 : À gauche : courbes d'entraînement de la version v2.0 Light. À droite : courbes d'entraînement de la version v2.0 Light après 200 epochs. Les deux expériences montrent une convergence stable avec une diminution progressive de la loss totale et une amélioration du PSNR de validation au cours de l'apprentissage.

La figure 4.4 illustre la dynamique d'entraînement de la version v3.0 selon les deux phases.

En Phase 1, la train loss décroît régulièrement de 0,72 à 0,43 et la validation loss converge vers 0,47, avec un gap stable de 0,04 indiquant une généralisation satisfaisante du générateur.

En Phase 2, la légère hausse de la validation loss est attendue : la fonction de perte intègre désormais le terme adversarial λ_{adv} , ce qui la rend non directement comparable à la Phase 1. La discontinuité observée à l'époque 65 correspond au rééquilibrage intentionnel des coefficients λ_{ID} et λ_{adv} pour corriger l'identity drift, sans perte des poids acquis grâce au mécanisme de checkpoint.




FIG. 4.4 : Courbes d’entraînement de la version v3.0 : Phase 1 (époches 1–50) – pré-entraînement du générateur seul ; Phase 2 (époches 51–75) – introduction du discriminateur PatchGAN et entraînement adversarial. La chute de la Loss D à l’époque 65 correspond à la correction des hyperparamètres appliquée pour remédier au phénomène d’identity drift (voir la description de la correction dans le chapitre 3).




FIG. 4.5 : Courbes d’entraînement de la version v3.1 (entraînement conjoint). La courbe bleue (Train Loss G) montre la décroissance régulière de la perte du générateur, passant de 0,8247 à l’époque 1 à 0,4825 à l’époque 80. La courbe orange (Validation Loss) descend de 0,6500 à l’époque 5 à son minimum de 0,5204 à l’époque 75, démontrant une excellente capacité de généralisation. Le gap stable (moyenne 0,038) confirme l’absence d’overfitting, et les légères oscillations après l’époque 60 sont caractéristiques de l’équilibrage continu entre générateur et discriminateur dans un GAN.

4.3.4 Résultats qualitatifs sur l’ensemble de validation

Les résultats qualitatifs de validation ci-dessous sont présentés sur un batch fixe de 4 images représentatives de l’ensemble de validation, utilisées tout au long de l’entraînement pour surveiller la progression. Les figures 4.6 à 4.10 présentent les résultats visuels obtenus par les principales versions de MEFSR-GAN.




FIG. 4.6 : Résultats qualitatifs de la version 1.



FIG. 4.7 : Résultats qualitatifs de la version 2.



FIG. 4.8 : Résultats qualitatifs de la version v3.0 GAN (entraînement en deux phases, LSGAN).



FIG. 4.9 : Résultats qualitatifs de la version v3.1 GAN (entraînement conjoint, LSGAN).




FIG. 4.10 : Résultats qualitatifs de la version v4 (WGAN-GP).

Observations qualitatives : La **baseline bicubique** produit des images très floues, sans détails fins. La version **v1.0.3** donne des contours nets et une bonne préservation de l'identité, mais présente des artéfacts de blocage visibles dans les zones uniformes (joues, front). La version **v2.0 Light** améliore les détails fins (cheveux, texture de peau) et les contours sont légèrement mieux définis, avec une réduction des artéfacts de blocage par rapport à v1.0.3. La version **v3.0 GAN** réalise une suppression complète et naturelle du masque, des textures de peau réalistes, une absence d'artéfacts visibles et une identité faciale bien préservée. La version **v3.1 GAN** apporte une amélioration supplémentaire de la netteté des contours (yeux, lèvres) et des textures de peau. Enfin, la version **v4 (WGAN-GP)** donne des résultats visuellement proches de v3.1, avec parfois un aspect légèrement plus lissé. Toutes les versions reconstruisent correctement les zones masquées, mais les versions 3.0 et 3.1 offrent les résultats les plus naturels et convaincants visuellement grâce à l'apprentissage adversarial.

4.3.5 Évaluation de la robustesse sur l'ensemble de test

Pour évaluer la capacité de généralisation et la robustesse de nos modèles adversariaux, nous les avons testés sur l'ensemble de test (2469 images non vues pendant l'entraînement ni la validation). La figure 4.11 présente les résultats qualitatifs obtenus

par les trois versions GAN sur 7 exemples représentatifs du test set.




FIG. 4.11 : Comparaison côte à côte des reconstructions obtenues par les trois versions GAN sur 7 images du test set. De gauche à droite : entrée LR (masquée), sortie de v3.0 (2 phases), sortie de v3.1 (entraînement conjoint), sortie de v4 (WGAN-GP) et cible HR.

Observations qualitatives sur le test set : La version **v3.0 GAN (2 phases)** produit des visages globalement cohérents avec une suppression correcte du masque. Toutefois, certaines zones reconstruites restent légèrement floues, notamment au niveau de la bouche, des joues et des contours du visage, et les textures de peau demeurent moins réalistes que dans les versions suivantes. La version **v3.1 GAN (entraînement conjoint)** améliore significativement la qualité visuelle : les contours des yeux, des lèvres et du visage

apparaissent plus nets, les textures de peau sont mieux préservées et les reconstructions sont plus naturelles, avec une identité faciale davantage respectée. Enfin, la version **v4 WGAN-GP** obtient les meilleurs scores PSNR sur l'ensemble des exemples présentés. Les reconstructions restent visuellement proches de celles produites par v3.1 : certaines images présentent une apparence légèrement plus lissée, tandis que d'autres bénéficient d'une meilleure homogénéité des textures. Le gain quantitatif apporté par WGAN-GP demeure cependant relativement faible sur le plan perceptuel.

4.3.6 Analyse synthétique des performances par version

L'analyse des versions successives de MEFSR-GAN permet de dégager plusieurs enseignements clés.

Apport des composantes de la perte. La comparaison des versions reconstructives (v1.0.1, v1.0.2, v1.0.3) montre que l'ajout de la perte SSIM améliore le PSNR de **+0,19 dB** et le SSIM de 0,7841 à 0,8090. Le remplacement de la MSE par un mix MAE prédominant ($\text{MAE} \times 0,8 + \text{MSE} \times 0,2$) associé à une augmentation des données apporte un gain supplémentaire de **+0,23 dB**, portant le PSNR à 25,03 dB et le SSIM à 0,8163. La perte perceptuelle (VGG16), présente dès la première version, contribue quant à elle à la qualité visuelle globale, comme le confirme son retrait expérimental (chute de 0,51 dB).

Choix du nombre de blocs RRDB. La version v2.0 (12 RRDB) souffre d'une surcomplexité (9,5 M paramètres pour 1 500 pixels) et de réglages inadaptés, avec un PSNR de seulement 23,57 dB. La version allégée v2.0 Light (4 RRDB) réduit la capacité à 4,5 M paramètres, recalibre les poids ($\lambda_{\text{ID}} = 0,01$, $\lambda_{\text{SSIM}} = 0,1$) et atteint 24,82 dB PSNR, soit un écart de seulement -0,20 dB par rapport à v1.0.3, tout en intégrant l'attention et les blocs RRDB.

Stratégies adversariales. Les versions GAN (v3.0, v3.1, v4) privilégient la qualité visuelle (textures réalistes, suppression naturelle du masque) au détriment d'une légère baisse des métriques pixel-wise, phénomène classique des GAN. L'entraînement conjoint (v3.1) surpasse l'approche en deux phases (v3.0) et le WGAN-GP (v4), qui dégrade la similarité structurelle (SSIM 0,728 contre 0,790 pour v3.1). Ainsi, **v3.1 est retenue comme version finale**, offrant le meilleur compromis entre fidélité objective (24,49 dB, 0,7902) et réalisme perceptuel.

4.3.7 Version 3.1 (GAN end-to-end) : Résultats finaux

La version 3.1 constitue le modèle final entraîné sur l'ensemble complet du dataset CelebA-HQ masqué avec discriminateur PatchGAN intégré de bout en bout. Cette version

a été évaluée sur les 2 469 images du test set selon deux axes : la qualité de reconstruction (PSNR, SSIM par catégories) et la préservation de l'identité faciale (similarité cosinus, distance euclidienne).

Résultats quantitatifs par catégories de qualité

Le tableau 4.5 présente la distribution des images selon leur qualité PSNR reconstruite.

TAB. 4.5 : Distribution de qualité — Version v3.1_GAN (2 469 images test)

Catégorie de qualité	Plage PSNR	Nombre	Pourcentage	SSIM moyen
Excellente	≥ 30 dB	3	0,1%	0,8969
Très bonne	29–30 dB	19	0,8%	0,8791
Bonne	27–29 dB	303	12,3%	0,8777
Acceptable	25–27 dB	803	32,5%	0,8395
Moyenne	23–25 dB	751	30,4%	0,8075
Faible	20–23 dB	475	19,2%	0,7228
Mauvaise	< 20 dB	115	4,7%	0,6207

Analyse de la distribution : La concentration médiane est de 62,9% des images (803 + 751), situées entre 23 et 27 dB (catégories Acceptable et Moyenne), ce qui indique une reconstruction solide dans la plage de référence déjà établie. La haute qualité (27+ dB) concerne 13,2% des images (325 images) qui dépassent 27 dB, confirmant que le modèle v3.1 réalise des reconstructions de qualité élevée dans un sous-ensemble de cas. Enfin, la performance en queue basse est de 4,7% (115 images) restant sous 20 dB, ce qui révèle que le modèle peine sur certains cas difficiles (masques complexes, variations extrêmes de pose ou d'éclairage).



FIG. 4.12 : Comparaison visuelle des reconstructions par catégorie de qualité — Version v3.1_GAN. Pour chaque catégorie, le panneau de gauche montre l'entrée basse résolution masquée (Input LR), le panneau du milieu la sortie du modèle (Output SR) avec PSNR et SSIM, et le panneau de droite l'image de référence haute résolution sans masque (Target HR). Les masques sont visualisés en bleu. La qualité visuelle s'améliore clairement des catégories Mauvaise (bas) à Excellente (haut).

Résultats d'évaluation de l'identité faciale

La préservation de l'identité a été évaluée en calculant la similarité cosinus et la distance euclidienne entre les embeddings FaceNet de l'image reconstruite et de l'image de référence. Le tableau 4.6 synthétise ces résultats.

TAB. 4.6 : Statistiques d'identité — Version v3.1_GAN (2 469 images)

Métrique d'identité	Valeur	Intervalle
Similarité cosinus — Moyenne	0,7317	[0,1115 – 0,9315]
Similarité cosinus — Écart-type	0,1075	–
Distance euclidienne — Moyenne	0,7191	[0,3701 – 1,3330]
Distance euclidienne — Écart-type	0,1397	–

Distribution catégorique de l'identité : La table 4.7 détaille la répartition qualitative de la préservation d'identité.

TAB. 4.7 : Catégories de préservation d'identité — v3.1_GAN

Catégorie	Nombre	Pourcentage	Interprétation
Excellent	244	9,9%	Reconstruction fidèle, identité préservée
Bon	1 437	58,2%	Similarité satisfaisante, identité lisible
Moyen	708	28,7%	Dégradation partielle, identité ambiguë
Faible	67	2,7%	Faible similarité, identité altérée
Très faible	13	0,5%	Perte quasi-totale d'identité
Bon ou mieux	1 681	68,1%	Résultat positif

Analyse détaillée : Les performances satisfaisantes (catégories Excellent et Bon) concernent 68,1% des reconstructions, qui préservent l'identité de manière lisible, confirmant que le modèle réussit globalement la tâche de préservation identitaire. La performance moyenne (28,7% en catégorie Moyen) montre une identité encore identifiable mais avec une certaine dégradation, ce qui reflète la difficulté intrinsèque du problème : reconstruire un visage masqué à très basse résolution (32×32) sans priors complets. Enfin, les cas critiques (3,2%, soit 80 images) présentent une faible ou très faible préservation d'identité, probablement associée à des masques très volumineux (occlusion supérieure à 40%), à des variations extrêmes de pose ou d'éclairage, ou à une dégradation très sévère de l'entrée.

4.4 Comparaison avec l'état de l'art

TAB. 4.8 : Comparaison complète avec les méthodes de l'état de l'art

Méthode	Année	Tâche	Dataset	Nombre d'images	Masque	Résolution	PSNR	SSIM
Bicubic	–	Interpolation	–	–	Non	$\times 4$	23,00	0,65
FSRNet [4]	2018	SR + priors	Helen+CelebA	20 330	Non	$\times 8$	25,87	0,760
FCSR-GAN [3]	2019	Complétion+SR	CelebA	162 770	Oui	$\times 4$	24,75	0,761
EIPNet [2]	2021	Contours+id.	CelebA	162 770	Non	$\times 8^a$	25,08	0,7429
JDSR-GAN [5]	2023	SR masqués	CelebA	162 770	Oui	$\times 4$	29,18	0,855
EFBPGAN [1]	2024	SR contours	FFHQ	70 000	Non	$\times 16^b$	27,05	–
SANet [6]	2025	SR+attention	CelebA	$\sim 202k$	Non	$\times 4$	32,36	0,924
v1.0.3	2026	SR masqués	CelebA-HQ mq.	24 678	Oui	$\times 4$	25,03	0,8163
v2.0 Light	2026	ESRGAN+att.	CelebA-HQ mq.	24 678	Oui	$\times 4$	24,82	0,8128
v3.0 GAN	2026	3mod.+PatchGAN	CelebA-HQ mq.	24 678	Oui	$\times 4$	23,45	0,7711
v3.1 GAN	2026	LSGAN conjoint	CelebA-HQ mq.	24 678	Oui	$\times 4$	24,49	0,7902
v4 (WGAN-GP)	2026	WGAN-GP	CelebA-HQ mq.	24 678	Oui	$\times 4$	24,58	0,7277

^a EIPNet : performances sur CelebA ($\times 8$).

^b EFBPGAN : évalué en $\times 16$ uniquement ; aucune valeur SSIM rapportée dans le papier original.

Note : JDSR-GAN atteint 29,18 dB / 0,855 en $\times 4$ et 26,45 dB / 0,763 en $\times 8$.

Interprétation des résultats et discussion des objectifs L'examen des performances de nos différentes versions permet de dégager plusieurs enseignements. La version purement reconstructive v1.0.3 atteint un PSNR de 25,03 dB et un SSIM de 0,8163, se situant au-delà de FCSR-GAN (24,75 dB, 0,761) et proche de FSRNet (25,87 dB, 0,760), bien que ces deux méthodes ne soient pas conçues pour les visages masqués. En présence d'une occlusion, JDSR-GAN constitue la référence absolue (29,18 dB, 0,855 en $\times 4$), mais avec un modèle très lourd (36,7 M paramètres).

Nos versions adversariales (v3.0, v3.1 et v4) privilégient la qualité perceptuelle au détriment des métriques pixel-wise, conformément au compromis classique des GAN. La version v3.1 affiche un PSNR de 24,49 dB et un SSIM de 0,7902. Ces valeurs moyennes n'atteignent pas les objectifs quantitatifs fixés dans le chapitre 1 (25 dB, 0,80), mais elles s'en approchent très fortement. Il convient cependant de nuancer ce constat : avec un écart-type de $\pm 2,38$ dB, une fraction significative des reconstructions dépasse individuellement le seuil de 25 dB — le tableau 4.6 montre en effet que 45,7 % des images test

atteignent ou dépassent ce seuil (catégories Acceptable, Bonne, Très bonne et Excellente réunies). Cet écart sur la moyenne s’explique par trois facteurs : (i) l’entraînement adversarial favorise la qualité visuelle et la suppression naturelle du masque ; (ii) la tâche est particulièrement difficile avec une entrée 32×32 (1 500 pixels) et une occlusion d’environ 40 % du visage ; (iii) notre dataset d’entraînement (24 678 paires) est modeste comparé aux corpus de l’état de l’art (CelebA complet : 200 000 images). Néanmoins, la v3.1 dépasse de 1,49 dB la baseline bicubique, et son SSIM de 0,7902 reste très proche de l’objectif. La v1.0.3, purement reconstructive, atteint exactement les deux objectifs fixés (25,03 dB, SSIM 0,8163), confirmant qu’ils sont pleinement réalisables sur ce dataset sans contrainte adversariale.

De plus, la compacité de notre modèle (9,4 M paramètres) le rend 3,9 fois plus léger que JDSR-GAN, un atout majeur pour un déploiement sur ressources limitées (GPU Kaggle). Enfin, la comparaison des résolutions mérite d’être nuancée : les méthodes concurrentes opèrent souvent à des échelles plus élevées ($128 \times 128 \rightarrow 512 \times 512$), ce qui rend la reconstruction moins ardue que notre passage de 32×32 à 128×128 .

Conclusion

Les expériences menées confirment que la version **v3.1 GAN (entraînement conjoint)** offre le meilleur compromis : un PSNR de 24,49 dB, un SSIM de 0,7902, et une excellente qualité perceptuelle, pour un modèle de seulement 9,4 millions de paramètres. L’architecture ResNet simple (v1.0.3) avec pertes bien calibrées reste la meilleure en termes de métriques quantitatives pures (25,03 dB, SSIM 0,8163), atteignant pleinement les objectifs fixés. L’approche WGAN-GP n’a pas démontré de supériorité sur notre tâche. La synthèse complète des contributions et les perspectives de ce travail sont présentées dans la conclusion générale.

Conclusion générale

Synthèse des travaux

Ce mémoire s’inscrit dans le contexte post-pandémique où le port généralisé du masque facial a fortement dégradé les performances des systèmes de reconnaissance faciale. L’objectif était de développer une méthode de super-résolution capable de restaurer une image haute résolution (128×128) à partir d’une entrée très basse résolution (32×32) avec occlusion d’environ 40 % du visage, tout en préservant l’identité et les détails structurels.

Nous proposons MEFSR-GAN, une architecture modulaire, légère et entraînable de bout en bout, dont l’originalité tient à l’association d’un guidage par contours, d’une perte d’identité explicite (FaceNet) et d’une fonction de perte composite (MAE+MSE, perceptuelle VGG, SSIM), le tout dans un modèle de faible complexité.

Entraîné sur un sous-ensemble de CelebA-HQ masqué (environ 24 000 paires) sur la plateforme Kaggle, le modèle produit des résultats compétitifs malgré des ressources limitées. La version purement reconstructive v1.0.3 atteint 25,03 dB PSNR et 0,8163 SSIM, atteignant pleinement les objectifs quantitatifs fixés ($\text{PSNR} \geq 25$ dB, $\text{SSIM} \geq 0,80$) et surpassant FCSR-GAN (24,75 dB, 0,761), seule méthode comparable traitant conjointement masque et super-résolution en $\times 4$. Notre version finale v3.1, retenue comme implémentation complète de MEFSR-GAN car elle intègre le générateur à trois modules et le discriminateur PatchGAN entraîné conjointement, ne comporte que 9,4 millions de paramètres — soit $3,9\times$ moins que JDSR-GAN. Elle améliore sensiblement la qualité visuelle perçue (suppression naturelle du masque, textures réalistes) au prix d’une légère baisse des métriques pixel-wise par rapport à v1.0.3, phénomène classique des GAN documenté dans [9]. Cette distinction est importante : v1.0.3 prouve que les objectifs quantitatifs sont atteignables sur ce dataset, tandis que v3.1 constitue l’aboutissement architectural du projet.

Limites

Plusieurs limites méritent d’être soulignées. Tout d’abord, l’entraînement repose sur environ 24 000 paires, une taille modeste comparée aux corpus utilisés dans certains travaux (CelebA complet, FFHQ); un dataset plus vaste améliorerait sans doute la généralisation. Ensuite, comme dans la plupart des études (JDSR-GAN, FCSR-GAN), les occlusions sont générées artificiellement. La robustesse du modèle face à des masques réels (différentes formes, couleurs, textures) n’a pas été évaluée systématiquement. Par ailleurs, la version GAN a nécessité environ 40 heures d’entraînement sur GPU Tesla P100, ce qui limite les itérations rapides. Enfin, le modèle n’est optimisé que pour un facteur d’échelle $\times 4$; l’adapter à plusieurs facteurs ($\times 2$, $\times 8$) demanderait des modifications non triviales.

Perspectives

Ce travail ouvre plusieurs pistes d’amélioration. On pourrait concevoir un réseau capable de gérer dynamiquement plusieurs facteurs d’échelle ($\times 2$, $\times 4$, $\times 8$) à l’aide de blocs de mise à l’échelle conditionnelle. Il serait également intéressant d’entraîner un module de détection d’occlusion pour ne plus avoir à fournir le masque binaire en entrée, et de valider le modèle sur des images réelles (base LDHF, vidéosurveillance). Du côté de la stabilité des GAN, des techniques comme la normalisation spectrale ou un discriminateur multi-échelles pourraient limiter la dérive d’identité sans réglage manuel. En outre, la légèreté de l’architecture la rend propice à un déploiement mobile pour une inférence en temps réel sur smartphone ou en périphérie (edge computing). Enfin, on pourrait utiliser notre module de super-résolution comme pré-traitement pour un système de reconnaissance faciale et mesurer le gain de précision en présence de masques.

En conclusion, ce travail démontre qu’une architecture end-to-end légère, même entraînée sur un dataset modeste, peut rivaliser avec des modèles beaucoup plus lourds pour la super-résolution de visages masqués, à condition d’intégrer un guidage par contours, des pertes perceptuelles et une régularisation adaptée. La version **v3.1 GAN**, retenue comme version finale avec 24,49 dB PSNR et 0,7902 SSIM, offre le meilleur compromis entre métriques quantitatives et qualité visuelle, ouvrant la voie à des applications où fidélité structurelle et réalisme perceptuel sont tous deux requis.

Bibliographie

- [1] Cheng, X., & Siu, W.-C. *Edge fusion back projection GAN for large scale face super resolution*. Journal of Visual Communication and Image Representation, vol. 100, p. 104143, 2024.
- [2] Kim, J., Li, G., Yun, I., Jung, C., & Kim, J. *Edge and identity preserving network for face super-resolution (EIPNet)*. Neurocomputing, vol. 446, pp. 11–22, 2021.
- [3] Cai, J., Han, H., Shan, S., & Chen, X. *FCSR-GAN : Joint face completion and super-resolution via multi-task learning*. In : 14th IEEE International Conference on Automatic Face and Gesture Recognition (FG), pp. 1–8, 2019.
- [4] Chen, Y., Tai, Y., Liu, X., Shen, C., & Yang, J. *FSRNet : End-to-end learning face super-resolution with facial priors*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2492–2501, 2018.
- [5] Gao, G., Tang, L., Wu, F., Lu, H., & Yang, J. *JDSR-GAN : Constructing an efficient joint learning network for masked face super-resolution*. IEEE Transactions on Multimedia, vol. 25, pp. 1505–1512, 2023.
- [6] Li, L., Zhang, Y., Yuan, L., & Gao, X. *SANet : Face super-resolution based on self-similarity prior and attention integration*. Pattern Recognition, vol. 157, p. 110854, 2025.
- [7] Zeng, K., Wang, Z., Lu, T., Chen, J., Wang, J., & Xiong, Z. *Self-attention learning network for face super-resolution*. Neural Networks, vol. 160, pp. 164–174, 2023.
- [8] Liu, Z., Luo, P., Wang, X., & Tang, X. *Deep learning face attributes in the wild*. In : Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 3730–3738, 2015.
- [9] Wang, X., Yu, K., Wu, S., Gu, J., Liu, Y., Dong, C., & Change Loy, C. *ESRGAN : Enhanced super-resolution generative adversarial networks*. In : Proceedings of the European Conference on Computer Vision Workshops (ECCVW), 2018.
- [10] Isola, P., Zhu, J.-Y., Zhou, T., & Efros, A. A. *Image-to-image translation with conditional adversarial networks*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5967–5976, 2017.
- [11] Mao, X., Li, Q., Xie, H., Lau, R. Y. K., Wang, Z., & Paul Smolley, S. *Least squares generative adversarial networks*. In : Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 2813–2821, 2017.
- [12] Gulrajani, I., Ahmed, F., Arjovsky, M., Dumoulin, V., & Courville, A. *Improved training of Wasserstein GANs*. In : Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017.
- [13] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., & Bengio, Y. *Generative adversarial nets*. In : Advances in Neural Information Processing Systems (NeurIPS), vol. 27, 2014.

- [14] Johnson, J., Alahi, A., & Fei-Fei, L. *Perceptual losses for real-time style transfer and super-resolution*. In : Proceedings of the European Conference on Computer Vision (ECCV), pp. 694–711, 2016.
- [15] Dong, C., Loy, C. C., He, K., & Tang, X. *Learning a deep convolutional network for image super-resolution*. In : Proceedings of the European Conference on Computer Vision (ECCV), pp. 184–199, 2014.
- [16] Kim, J., Lee, J. K., & Lee, K. M. *Accurate image super-resolution using very deep convolutional networks*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1646–1654, 2016.
- [17] Canny, J. *A computational approach to edge detection*. IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 8, no. 6, pp. 679–698, 1986.
- [18] Simonyan, K., & Zisserman, A. *Very deep convolutional networks for large-scale image recognition*. In : International Conference on Learning Representations (ICLR), 2015.
- [19] He, K., Zhang, X., Ren, S., & Sun, J. *Deep residual learning for image recognition*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778, 2016.
- [20] Schroff, F., Kalenichenko, D., & Philbin, J. *FaceNet : A unified embedding for face recognition and clustering*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 815–823, 2015.
- [21] Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. *Image quality assessment : from error visibility to structural similarity*. IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600–612, 2004.
- [22] Kingma, D. P., & Ba, J. *Adam : A method for stochastic optimization*. In : International Conference on Learning Representations (ICLR), 2015.
- [23] Le, V., Brandt, J., Lin, Z., Bourdev, L., & Huang, T. S. *Interactive facial feature localization*. In : Proceedings of the European Conference on Computer Vision (ECCV), pp. 679–692, 2012.
- [24] Guo, S., Yan, Z., Zhang, K., Zuo, W., & Zhang, L. *Toward convolutional blind denoising of real photographs*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1712–1722, 2019.
- [25] Guo, Y., Chen, J., Wang, J., Chen, Q., Cao, J., Deng, Z., Xu, Y., & Tan, M. *Closed-loop matters : Dual regression networks for single image super-resolution*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5407–5416, 2020.
- [26] Ma, C., Jiang, Z., Rao, Y., Lu, J., & Zhou, J. *Deep face super-resolution with iterative collaboration between attentive recovery and landmark estimation*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5568–5577, 2020.
- [27] Karras, T., Laine, S., & Aila, T. *A style-based generator architecture for generative adversarial networks*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 4401–4410, 2019.
- [28] Karras, T., Laine, S., Aittala, M., Hellsten, J., Lehtinen, J., & Aila, T. *Analyzing and improving the image quality of StyleGAN*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 8110–8119, 2020.
- [29] Lee, C.-H., Liu, Z., Wu, L., & Luo, P. *MaskGAN : Towards diverse and interactive facial image manipulation*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5549–5558, 2020. (CelebA-HQ dataset)

- [30] Zhang, Y., Li, K., Li, K., Wang, L., Zhong, B., & Fu, Y. *Image super-resolution using very deep residual channel attention networks*. In : Proceedings of the European Conference on Computer Vision (ECCV), pp. 286–301, 2018.
- [31] Wang, X., Xie, L., Dong, C., & Shan, Y. *Real-ESRGAN : Training real-world blind super-resolution with pure synthetic data*. In : Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 1905–1914, 2021.
- [32] Menon, S., Damian, A., Hu, S., Ravi, N., & Rudin, C. *PULSE : Self-supervised photo upsampling via latent space exploration of generative models*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2437–2445, 2020.
- [33] Yang, T., Ren, P., Xie, X., & Zhang, L. *GAN prior embedded network for blind face restoration in the wild*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 672–681, 2021.
- [34] Wang, X., Li, Y., Zhang, H., & Shan, Y. *Towards real-world blind face restoration with generative facial prior*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 9168–9178, 2021.
- [35] Chan, K. C. K., Wang, X., Xu, X., Gu, J., & Loy, C. C. *GLEAN : Generative latent bank for large-factor image super-resolution*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 14245–14254, 2021.
- [36] Cao, Q., Shen, L., Xie, W., Parkhi, O. M., & Zisserman, A. *VGGFace2: A dataset for recognising faces across pose and age*. In : 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG), pp. 67–74, 2018.
- [37] Kim, D., Kim, M., Kwon, G., & Kim, D.-S. *Progressive face super-resolution via attention to facial landmark*. In : Proceedings of the British Machine Vision Conference (BMVC), p. 192, 2019.
- [38] Lu, T., Wang, J., Jiang, J., & Zhang, Y. *Global-local fusion network for face super-resolution*. *Neurocomputing*, vol. 387, pp. 309–320, 2020.
- [39] Hsu, C.-C., Lin, C.-W., Su, W.-T., & Cheung, G. *SiGAN : Siamese generative adversarial network for identity-preserving face hallucination*. *IEEE Transactions on Image Processing*, vol. 28, no. 12, pp. 6225–6236, 2019.
- [40] Hui, Z., Wang, X., & Gao, X. *Fast and accurate single image super-resolution via information distillation network*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 723–731, 2018.
- [41] Fu, S., Lu, L., Li, H., Li, Z., Wu, W., Paul, A., Jeon, G., & Yang, X. *A real-time super-resolution method based on convolutional neural networks*. *Circuits, Systems, and Signal Processing*, vol. 39, no. 2, pp. 805–817, 2020.
- [42] Gatys, L. A., Ecker, A. S., & Bethge, M. *A neural algorithm of artistic style*. arXiv preprint arXiv :1508.06576, 2015.
- [43] Li, Y., Liu, S., Yang, J., & Yang, M.-H. *Generative Face Completion*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5892–5900, 2017.
- [44] Ledig, C., Theis, L., Huszár, F., Caballero, J., Cunningham, A., Acosta, A., Aitken, A., Tejani, A., Totz, J., Wang, Z., & Shi, W. *Photo-realistic single image super-resolution using a generative adversarial network*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 4681–4690, 2017.

- [45] Yu, X., & Porikli, F. *Ultra-resolving face images by discriminative generative networks*. In : European Conference on Computer Vision (ECCV), pp. 318–333, 2016.
- [46] Tuzel, O., Taguchi, Y., & Hershey, J. R. *Global-local face upsampling network*. arXiv preprint arXiv :1603.07235, 2016.
- [47] Zhang, R., Isola, P., Efros, A. A., Shechtman, E., & Wang, O. *The unreasonable effectiveness of deep features as a perceptual metric*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 586–595, 2018.
- [48] Mei, Y., Fan, Y., Zhou, Y., Huang, L., Huang, T. S., & Shi, H. *Image super-resolution with cross-scale non-local attention and exhaustive self-exemplars mining*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5690–5699, 2020.
- [49] Chen, C., Gong, D., Wang, H., Li, Z., & Wong, K.-Y. K. *Learning spatial attention for face super-resolution*. IEEE Transactions on Image Processing, vol. 30, pp. 1219–1231, 2021.
- [50] Lu, T., Wang, Y., Zhang, Y., Wang, Y., Liu, W., Wang, Z., & Jiang, J. *Face hallucination via split-attention in split-attention network*. In : Proceedings of the 29th ACM International Conference on Multimedia (ACM MM), pp. 5501–5509, 2021.
- [51] Mei, Y., Fan, Y., & Zhou, Y. *Image super-resolution with non-local sparse attention*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 3517–3526, 2021.
- [52] Bao, Q., Gang, B., Yang, W., Zhou, J., & Liao, Q. *Attention-driven graph neural network for deep face super-resolution*. IEEE Transactions on Image Processing, vol. 31, pp. 6455–6470, 2022.
- [53] Gao, G., Xu, Z., Li, J., Yang, J., Zeng, T., & Qi, G.-J. *CTCNet : A CNN-Transformer cooperation network for face image super-resolution*. IEEE Transactions on Image Processing, vol. 32, pp. 1978–1991, 2023.
- [54] Bao, Q., Liu, Y., Gang, B., Yang, W., & Liao, Q. *SCTANet : A spatial attention-guided CNN-Transformer aggregation network for deep face image super-resolution*. IEEE Transactions on Multimedia, vol. 25, pp. 8554–8565, 2023.
- [55] Wang, C., Jiang, J., Zhong, Z., & Liu, X. *Spatial-frequency mutual learning for face super-resolution*. In : Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 22356–22366, 2023.
- [56] Lim, B., Son, S., Kim, H., Nah, S., & Lee, K. M. *Enhanced deep residual networks for single image super-resolution*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), pp. 136–144, 2017.
- [57] Liang, J., Cao, J., Sun, G., Zhang, K., Van Gool, L., & Timofte, R. *SwinIR : Image restoration using Swin Transformer*. In : Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 1833–1844, 2021.
- [58] Maeng, H., Liao, S., Kang, D., Lee, S.-W., & Jain, A. K. *Nighttime face recognition at long distance : Cross-distance and cross-spectral matching*. In : Asian Conference on Computer Vision (ACCV), pp. 708–721, 2012.
- [59] Zhang, Y., Tian, Y., Kong, Y., Zhong, B., & Fu, Y. *Residual dense network for image super-resolution*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2472–2481, 2018.

- [60] Dai, T., Cai, J., Zhang, Y., Xia, S.-T., & Zhang, L. *Second-order attention network for single image super-resolution*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 11065–11074, 2019.
- [61] Li, Z., Yang, J., Liu, Z., Yang, X., Jeon, G., & Wu, W. *Feedback network for image super-resolution*. In : Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 3867–3876, 2019.
- [62] Wang, Y., Lu, T., Xu, R., & Zhang, Y. *Face super-resolution by learning multi-view texture compensation*. In : International Conference on Multimedia Modeling (MMM), pp. 350–360, 2020.
- [63] Anwar, M. A., & Raychowdhury, A. *Masked Face Recognition for Secure Authentication*. arXiv preprint arXiv :2008.11104, 2020.